第 9 课　随机变量的数字特征（二）
大数定律及中心极限定理

重要不等式　　协方差　　相关系数　　大数定律　　中心极限定理

2026 年 11 月 9 日

回顾 & 测试

回顾

1. 随机变量的数字特征引入
2. 数学期望: 定义 | 意义 | 常见分布的数学期望 | 变量函数的数学期望 | 数学期望的性质 | 条件期望
3. 方差: 定义 | 计算 | 性质 | 常见分布的方差

回顾 & 测试

回顾

1. 随机变量的数字特征引入
2. 数学期望: 定义 | 意义 | 常见分布的数学期望 | 变量函数的数学期望 | 数学期望的性质 | 条件期望
3. 方差: 定义 | 计算 | 性质 | 常见分布的方差

随堂测试 (2025 年正确率 12.5%)

设 X 服从参数为 1 的泊松分布，则 $\mathbb{E}(|X-\mathbb{E}(X)|)=____$

回顾 & 测试

随堂测试 (2025 年正确率 12.5%)

设 X 服从参数为 1 的泊松分布，则 $\mathbb{E}(|X-\mathbb{E}(X)|)=____$

回顾 & 测试

随堂测试 (2025 年正确率 12.5%)

设 X 服从参数为 1 的泊松分布，则 $\mathbb{E}(|X-\mathbb{E}(X)|)=____$

证明. 由 $X\sim\pi(1)$ 可知 $\mathbb{E}(X)=1$. 于是, 我们有

$$\mathbb{E}(|X-\mathbb{E}(X)|) \;=\; \mathbb{E}(|X-1|)=\sum_{k=0}^{\infty}|k-1|\cdot P\{X=k\}$$

回顾 & 测试

随堂测试 (2025 年正确率 12.5%)

设 X 服从参数为 1 的泊松分布，则 $\mathbb{E}(|X-\mathbb{E}(X)|)=____$

证明. 由 $X\sim\pi(1)$ 可知 $\mathbb{E}(X)=1$. 于是, 我们有

$$\begin{aligned}\mathbb{E}(|X-\mathbb{E}(X)|) &= \mathbb{E}(|X-1|)=\sum_{k=0}^{\infty}|k-1|\cdot P\{X=k\}\\ &= |0-1|\cdot P\{X=0\}+\sum_{k=1}^{\infty}(k-1)\cdot P\{X=k\}\end{aligned}$$

回顾 & 测试

随堂测试 (2025 年正确率 12.5%)

设 X 服从参数为 1 的泊松分布，则 $\mathbb{E}(|X-\mathbb{E}(X)|)=____$

证明. 由 $X\sim\pi(1)$ 可知 $\mathbb{E}(X)=1$. 于是, 我们有

$$\begin{aligned}\mathbb{E}(|X-\mathbb{E}(X)|) &= \mathbb{E}(|X-1|)=\sum_{k=0}^{\infty}|k-1|\cdot P\{X=k\}\\ &= |0-1|\cdot P\{X=0\}+\sum_{k=1}^{\infty}(k-1)\cdot P\{X=k\}\\ &= \underbrace{|0-1|\cdot P\{X=0\}-(0-1)\cdot P\{X=0\}}_{=2\cdot P\{X=0\}}+\underbrace{\sum_{k=0}^{\infty}(k-1)\cdot P\{X=k\}}_{=\mathbb{E}(X-1)}\end{aligned}$$

回顾 & 测试

随堂测试 (2025 年正确率 12.5%)

设 X 服从参数为 1 的泊松分布，则 $\mathbb{E}(|X-\mathbb{E}(X)|)=____$

证明. 由 $X\sim\pi(1)$ 可知 $\mathbb{E}(X)=1$. 于是, 我们有

$$\begin{aligned}\mathbb{E}(|X-\mathbb{E}(X)|) &= \mathbb{E}(|X-1|)=\sum_{k=0}^{\infty}|k-1|\cdot P\{X=k\}\\ &= |0-1|\cdot P\{X=0\}+\sum_{k=1}^{\infty}(k-1)\cdot P\{X=k\}\\ &= \underbrace{|0-1|\cdot P\{X=0\}-(0-1)\cdot P\{X=0\}}_{=2\cdot P\{X=0\}}+\underbrace{\sum_{k=0}^{\infty}(k-1)\cdot P\{X=k\}}_{=\mathbb{E}(X-1)}\end{aligned}$$

根据分布律 $P\{X=k\}=\dfrac{\lambda^k}{k!}e^{-\lambda}$, $k=0,1,2\ldots$ 和期望的线性性，可以计算

$$\mathbb{E}(|X-\mathbb{E}(X)|)=2\cdot P\{X=0\}+\mathbb{E}(X-1)=\frac{2}{e}=2\cdot\frac{1}{e}+\mathbb{E}(X)-1=\frac{2}{e}$$

重要不等式

马尔可夫不等式

定理 1 (马尔可夫不等式)

设 X 是非负随机变量, 其数学期望存在, 则对任意 $a > 0$, 有

$$P\{X \geqslant a\} \leqslant \frac{\mathbb{E}(X)}{a}.$$

马尔可夫不等式

定理 1 (马尔可夫不等式)

设 X 是非负随机变量, 其数学期望存在, 则对任意 $a > 0$, 有

$$P\{X \geqslant a\} \leqslant \frac{\mathbb{E}(X)}{a}.$$

证明. 我们只证明连续型随机变量的情形. 令概率密度为 f, 由期望的定义:

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x f(x)\, dx$$

马尔可夫不等式

定理 1 (马尔可夫不等式)

设 X 是非负随机变量, 其数学期望存在, 则对任意 $a > 0$, 有

$$P\{X \geqslant a\} \leqslant \frac{\mathbb{E}(X)}{a}.$$

证明. 我们只证明连续型随机变量的情形. 令概率密度为 f, 由期望的定义:

$$\begin{aligned} \mathbb{E}(X) &= \int_{-\infty}^{\infty} x f(x)\,dx \\ &\geqslant \int_{a}^{\infty} x f(x)\,dx \quad \text{// 区间缩放, } X \geqslant 0 \end{aligned}$$

马尔可夫不等式

定理 1 (马尔可夫不等式)

设 X 是非负随机变量, 其数学期望存在, 则对任意 $a > 0$, 有

$$P\{X \geqslant a\} \leqslant \frac{\mathbb{E}(X)}{a}.$$

证明. 我们只证明连续型随机变量的情形. 令概率密度为 f, 由期望的定义:

$$\begin{aligned}
\mathbb{E}(X) &= \int_{-\infty}^{\infty} x f(x)\,dx \\
&\geqslant \int_{a}^{\infty} x f(x)\,dx \quad \text{// 区间缩放, } X \geqslant 0 \\
&\geqslant \int_{a}^{\infty} a f(x)\,dx \quad \text{// 函数缩放, } X \geqslant a
\end{aligned}$$

马尔可夫不等式

定理 1 (马尔可夫不等式)

设 X 是非负随机变量, 其数学期望存在, 则对任意 $a > 0$, 有

$$P\{X \geqslant a\} \leqslant \frac{\mathbb{E}(X)}{a}.$$

证明. 我们只证明连续型随机变量的情形. 令概率密度为 f, 由期望的定义:

$$\begin{aligned}
\mathbb{E}(X) &= \int_{-\infty}^{\infty} x f(x)\,dx \\
&\geqslant \int_{a}^{\infty} x f(x)\,dx \quad \text{// 区间缩放, } X \geqslant 0 \\
&\geqslant \int_{a}^{\infty} a f(x)\,dx \quad \text{// 函数缩放, } X \geqslant a \\
&= aP\{X \geqslant a\}
\end{aligned}$$

马尔可夫不等式

定理 1 (马尔可夫不等式)

设 X 是非负随机变量, 其数学期望存在, 则对任意 $a > 0$, 有

$$P\{X \geqslant a\} \leqslant \frac{\mathbb{E}(X)}{a}.$$

证明. 我们只证明连续型随机变量的情形. 令概率密度为 f, 由期望的定义:

$$\begin{aligned}
\mathbb{E}(X) &= \int_{-\infty}^{\infty} x f(x)\,dx \\
&\geqslant \int_{a}^{\infty} x f(x)\,dx \quad \text{// 区间缩放, } X \geqslant 0 \\
&\geqslant \int_{a}^{\infty} a f(x)\,dx \quad \text{// 函数缩放, } X \geqslant a \\
&= aP\{X \geqslant a\}
\end{aligned}$$

由 $a > 0$ 可知:

$$P\{X \geqslant a\} \leqslant \frac{\mathbb{E}(X)}{a}.$$

切比雪夫不等式

定理 2 (切比雪夫不等式)

设 X 是随机变量, 其数学期望和方差存在, 则对任意 $\epsilon > 0$, 有

$$P\{|X - \mathbb{E}(X)| \geqslant \epsilon\} \leqslant \frac{\mathbb{D}(X)}{\epsilon^2}.$$

切比雪夫不等式

定理 2 (切比雪夫不等式)

设 X 是随机变量, 其数学期望和方差存在, 则对任意 $\epsilon > 0$, 有

$$P\{|X - \mathbb{E}(X)| \geqslant \epsilon\} \leqslant \frac{\mathbb{D}(X)}{\epsilon^2}.$$

证明. 由于 X 的期望和方差均存在, 我们有

$$P\{|X - \mathbb{E}(X)| \geqslant \epsilon\} \leqslant P\{(X - \mathbb{E}(X))^2 \geqslant \epsilon^2\} \quad // \text{事件缩放}$$

切比雪夫不等式

定理 2 (切比雪夫不等式)

设 X 是随机变量, 其数学期望和方差存在, 则对任意 $\epsilon > 0$, 有

$$P\{|X - \mathbb{E}(X)| \geqslant \epsilon\} \leqslant \frac{\mathbb{D}(X)}{\epsilon^2}.$$

证明. 由于 X 的期望和方差均存在, 我们有

$$\begin{aligned} P\{|X - \mathbb{E}(X)| \geqslant \epsilon\} &\leqslant P\{(X - \mathbb{E}(X))^2 \geqslant \epsilon^2\} \quad \text{// 事件缩放} \\ &\leqslant \frac{\mathbb{E}((X - \mathbb{E}(X))^2)}{\epsilon^2} \quad \text{// 马尔可夫不等式} \end{aligned}$$

切比雪夫不等式

定理 2 (切比雪夫不等式)

设 X 是随机变量, 其数学期望和方差存在, 则对任意 $\epsilon > 0$, 有

$$P\{|X - \mathbb{E}(X)| \geqslant \epsilon\} \leqslant \frac{\mathbb{D}(X)}{\epsilon^2}.$$

证明. 由于 X 的期望和方差均存在, 我们有

$$\begin{aligned} P\{|X - \mathbb{E}(X)| \geqslant \epsilon\} &\leqslant P\{(X - \mathbb{E}(X))^2 \geqslant \epsilon^2\} && \text{// 事件缩放} \\ &\leqslant \frac{\mathbb{E}((X - \mathbb{E}(X))^2)}{\epsilon^2} && \text{// 马尔可夫不等式} \\ &\leqslant \frac{\mathbb{D}(X)}{\epsilon^2} && \text{// 方差的定义} \end{aligned}$$

切比雪夫不等式

例题 1

设种子的良种率为 1/6, 任选 600 粒, 估计“这 600 粒种子中良种所占比例与 1/6 之差的绝对值不超过 0.02”的概率.

切比雪夫不等式

例题 1

设种子的良种率为 1/6, 任选 600 粒, 估计 “这 600 粒种子中良种所占比例与 1/6 之差的绝对值不超过 0.02” 的概率.

证明. 设 X 为 600 粒种子中的良种数目, 则 $X \sim B(600, 1/6)$. 因此

$$\mathbb{E}(X) = 600 \times (1/6) = 100, \quad \mathbb{D}(X) = 600 \times (1/6) \times (1 - 1/6) = 83.33$$

切比雪夫不等式

例题 1

设种子的良种率为 1/6, 任选 600 粒, 估计 “这 600 粒种子中良种所占比例与 1/6 之差的绝对值不超过 0.02” 的概率.

证明. 设 X 为 600 粒种子中的良种数目, 则 $X \sim B(600, 1/6)$. 因此

$$\mathbb{E}(X) = 600 \times (1/6) = 100, \quad \mathbb{D}(X) = 600 \times (1/6) \times (1 - 1/6) = 83.33$$

由切比雪夫不等式可知:

$$P\left\{\left| \overbrace{\frac{X}{600}}^{\text{良种比例}} - \frac{1}{6} \right| \leqslant 0.02\right\} = P\{|X - \overbrace{100}^{\mathbb{E}(X)}| \leqslant 12\}$$

切比雪夫不等式

例题 1

设种子的良种率为 1/6, 任选 600 粒, 估计 “这 600 粒种子中良种所占比例与 1/6 之差的绝对值不超过 0.02” 的概率.

证明. 设 X 为 600 粒种子中的良种数目, 则 $X \sim B(600, 1/6)$. 因此

$$\mathbb{E}(X) = 600 \times (1/6) = 100, \quad \mathbb{D}(X) = 600 \times (1/6) \times (1 - 1/6) = 83.33$$

由切比雪夫不等式可知:

$$\begin{aligned} P\left\{\left| \overbrace{\frac{X}{600}}^{\text{良种比例}} - \frac{1}{6} \right| \leqslant 0.02\right\} &= P\{|X - \overbrace{100}^{\mathbb{E}(X)}| \leqslant 12\} \\ &\geqslant 1 - \frac{\mathbb{D}(X)}{12^2} = 0.4213. \end{aligned}$$

切比雪夫不等式

这两个不等式允许在随机变量 X 的分布未知的情况下, 估算概率下界:

切比雪夫不等式

这两个不等式允许在随机变量 X 的分布未知的情况下, 估算概率下界:

- 马尔可夫不等式可以估计概率 $P\{X < \epsilon\}$ 的下界:

$$P\{X < m\mathbb{E}(X)\} \geqslant 1 - \frac{1}{m}.$$

切比雪夫不等式

这两个不等式允许在随机变量 X 的分布未知的情况下, 估算概率下界:

- 马尔可夫不等式可以估计概率 $P\{X < \epsilon\}$ 的下界:

$$P\{X < m\mathbb{E}(X)\} \geqslant 1 - \frac{1}{m}.$$

- 切比雪夫不等式可以估计概率 $P\{|X - \mathbb{E}(X)| < \epsilon\}$ 的下界:

$$P\{|X - \mathbb{E}(X)| < m\sqrt{\mathbb{D}(X)}\} \geqslant 1 - \frac{1}{m^2};$$

  具体的例子有:

$$P\{|X - \mathbb{E}(X)| < 3\sqrt{\mathbb{D}(X)}\} \geqslant 0.8889, \quad P\{|X - \mathbb{E}(X)| < 4\sqrt{\mathbb{D}(X)}\} \geqslant 0.9375.$$

切比雪夫不等式

这两个不等式允许在随机变量 X 的分布未知的情况下, 估算概率下界:

- 马尔可夫不等式可以估计概率 $P\{X < \epsilon\}$ 的下界:

$$P\{X < m\mathbb{E}(X)\} \geqslant 1 - \frac{1}{m}.$$

- 切比雪夫不等式可以估计概率 $P\{|X - \mathbb{E}(X)| < \epsilon\}$ 的下界:

$$P\{|X - \mathbb{E}(X)| < m\sqrt{\mathbb{D}(X)}\} \geqslant 1 - \frac{1}{m^2};$$

  具体的例子有:

$$P\{|X - \mathbb{E}(X)| < 3\sqrt{\mathbb{D}(X)}\} \geqslant 0.8889, \quad P\{|X - \mathbb{E}(X)| < 4\sqrt{\mathbb{D}(X)}\} \geqslant 0.9375.$$

马尔可夫不等式仅使用期望, 切比雪夫还使用了方差, 后者更加精细. 但是, 它们终归都是比较粗糙的估计——如果分布已知, 则可以直接计算出精确值.

切比雪夫不等式

引理 3 (未证明的必要性)

设 X 是随机变量, 则

$$\mathbb{D}(X) = 0 \Longrightarrow P\{X = \mathbb{E}(X)\} = 1.$$

切比雪夫不等式

引理 3 (未证明的必要性)

设 X 是随机变量, 则

$$\mathbb{D}(X)=0 \Longrightarrow P\{X=\mathbb{E}(X)\}=1.$$

证明. 设 $\mathbb{D}(X)=0$, 此时 $\mathbb{E}(X)$ 存在. 于是,

$$P\{|X-\mathbb{E}(X)|>0\} = P\left\{\bigcup_{n=1}^{\infty}\{|X-\mathbb{E}(X)|\geqslant 1/n\}\right\}$$

切比雪夫不等式

引理 3 (未证明的必要性)

设 X 是随机变量, 则

$$\mathbb{D}(X)=0 \Longrightarrow P\{X=\mathbb{E}(X)\}=1.$$

证明. 设 $\mathbb{D}(X)=0$, 此时 $\mathbb{E}(X)$ 存在. 于是,

$$\begin{aligned} P\{|X-\mathbb{E}(X)|>0\} &= P\left\{\bigcup_{n=1}^{\infty}\{|X-\mathbb{E}(X)|\geqslant 1/n\}\right\} \\ &\leqslant \sum_{n=1}^{\infty} P\{|X-\mathbb{E}(X)|\geqslant 1/n\} \end{aligned}$$

切比雪夫不等式

引理 3 (未证明的必要性)

设 X 是随机变量, 则

$$\mathbb{D}(X)=0 \Longrightarrow P\{X=\mathbb{E}(X)\}=1.$$

证明. 设 $\mathbb{D}(X)=0$, 此时 $\mathbb{E}(X)$ 存在. 于是,

$$\begin{aligned} P\{|X-\mathbb{E}(X)|>0\} &= P\left\{\bigcup_{n=1}^{\infty}\{|X-\mathbb{E}(X)|\geqslant 1/n\}\right\} \\ &\leqslant \sum_{n=1}^{\infty} P\{|X-\mathbb{E}(X)|\geqslant 1/n\} \\ &\leqslant \sum_{n=1}^{\infty} n^2\mathbb{D}(X)=0 \quad \text{//切比雪夫不等式} \end{aligned}$$

切比雪夫不等式

引理 3 (未证明的必要性)

设 X 是随机变量, 则

$$\mathbb{D}(X)=0 \Longrightarrow P\{X=\mathbb{E}(X)\}=1.$$

证明. 设 $\mathbb{D}(X)=0$, 此时 $\mathbb{E}(X)$ 存在. 于是,

$$\begin{aligned} P\{|X-\mathbb{E}(X)|>0\} &= P\left\{\bigcup_{n=1}^{\infty}\{|X-\mathbb{E}(X)|\geqslant 1/n\}\right\} \\ &\leqslant \sum_{n=1}^{\infty} P\{|X-\mathbb{E}(X)|\geqslant 1/n\} \\ &\leqslant \sum_{n=1}^{\infty} n^2\mathbb{D}(X)=0 \quad \text{//切比雪夫不等式} \end{aligned}$$

因此

$$P\{|X-\mathbb{E}(X)|=0\}=1 \Longrightarrow P\{X=\mathbb{E}(X)\}=1.$$

协方差和相关系数

协方差

回顾 设 X, Y 是两个随机变量, 则

$$\mathbb{D}(X+Y) = \mathbb{D}(X) + \mathbb{D}(Y) + 2 \cdot \underbrace{\boxed{\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y)))}}_{X,Y \text{ 独立时为 } 0}.$$

协方差

回顾　设 X, Y 是两个随机变量, 则

$$\mathbb{D}(X+Y)=\mathbb{D}(X)+\mathbb{D}(Y)+2\cdot\underbrace{\boxed{\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y)))}}_{X,Y\text{ 独立时为 }0}.$$

这表明: 若 $\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y)))\neq 0$, 则两个随机变量存在一定的关系; 我们不妨用这个常数来描述两个变量的关联性.

协方差

回顾 设 X, Y 是两个随机变量, 则

$$\mathbb{D}(X+Y) = \mathbb{D}(X) + \mathbb{D}(Y) + 2 \cdot \underbrace{\boxed{\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y)))}}_{X,Y \text{ 独立时为 } 0}.$$

这表明: 若 $\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))) \neq 0$, 则两个随机变量存在一定的关系; 我们不妨用这个常数来描述两个变量的关联性.

定义 4

我们定义随机变量 X 与 Y 的*协方差*为

$$\mathbf{Cov}(X, Y) = \mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y).$$

协方差

回顾 设 X, Y 是两个随机变量, 则

$$\mathbb{D}(X+Y) = \mathbb{D}(X) + \mathbb{D}(Y) + 2 \cdot \underbrace{\boxed{\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y)))}}_{X,Y \text{ 独立时为 } 0}.$$

这表明: 若 $\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))) \neq 0$, 则两个随机变量存在一定的关系; 我们不妨用这个常数来描述两个变量的关联性.

定义 4

我们定义随机变量 X 与 Y 的*协方差*为

$$\mathbf{Cov}(X, Y) = \mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y).$$

利用协方差, 我们可以重写变量和的方差:

$$\mathbb{D}(X+Y) = \mathbb{D}(X) + \mathbb{D}(Y) + 2\,\mathbf{Cov}(X, Y)$$

协方差的性质

回顾

$$\mathbf{Cov}(X,Y)=\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))).$$

根据定义, 我们可以推导出协方差的性质:

协方差的性质

回顾

$$\mathrm{Cov}(X,Y)=\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))).$$

根据定义, 我们可以推导出协方差的性质:

1. $\mathrm{Cov}(X,Y)=\mathrm{Cov}(Y,X)$
2. $\mathrm{Cov}(X,X)=\mathbb{D}(X)$
3. $\mathrm{Cov}(aX,bY)=ab\,\mathrm{Cov}(X,Y)$
4. $\mathrm{Cov}(X+Y,Z)=\mathrm{Cov}(X,Z)+\mathrm{Cov}(Y,Z)$

协方差的性质

回顾

$$\mathrm{Cov}(X,Y)=\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))).$$

根据定义, 我们可以推导出协方差的性质:

1. $\mathrm{Cov}(X,Y)=\mathrm{Cov}(Y,X)$
2. $\mathrm{Cov}(X,X)=\mathbb{D}(X)$
3. $\mathrm{Cov}(aX,bY)=ab\,\mathrm{Cov}(X,Y)$
4. $\mathrm{Cov}(X+Y,Z)=\mathrm{Cov}(X,Z)+\mathrm{Cov}(Y,Z)$

利用协方差的性质, 可以推广得多个随机变量的线性组合的方差公式, 以三个为例:

$$\mathbb{D}(X+Y+Z) = \mathbb{D}(X+Y)+\mathbb{D}(Z)+2\,\mathrm{Cov}(X+Y,Z)$$

协方差的性质

回顾

$$\mathrm{Cov}(X,Y)=\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))).$$

根据定义, 我们可以推导出协方差的性质:

1. $\mathrm{Cov}(X,Y)=\mathrm{Cov}(Y,X)$
2. $\mathrm{Cov}(X,X)=\mathbb{D}(X)$
3. $\mathrm{Cov}(aX,bY)=ab\,\mathrm{Cov}(X,Y)$
4. $\mathrm{Cov}(X+Y,Z)=\mathrm{Cov}(X,Z)+\mathrm{Cov}(Y,Z)$

利用协方差的性质, 可以推广得多个随机变量的线性组合的方差公式, 以三个为例:

$$\begin{aligned}\mathbb{D}(X+Y+Z) &= \mathbb{D}(X+Y)+\mathbb{D}(Z)+2\,\mathrm{Cov}(X+Y,Z)\\ &= \mathbb{D}(X)+\mathbb{D}(Y)+2\,\mathrm{Cov}(X,Y)+\mathbb{D}(Z)+2\,\mathrm{Cov}(X,Z)+2\,\mathrm{Cov}(Y,Z)\end{aligned}$$

协方差的性质

回顾

$$\mathrm{Cov}(X,Y)=\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))).$$

根据定义, 我们可以推导出协方差的性质:

1. $\mathrm{Cov}(X,Y)=\mathrm{Cov}(Y,X)$
2. $\mathrm{Cov}(X,X)=\mathbb{D}(X)$
3. $\mathrm{Cov}(aX,bY)=ab\,\mathrm{Cov}(X,Y)$
4. $\mathrm{Cov}(X+Y,Z)=\mathrm{Cov}(X,Z)+\mathrm{Cov}(Y,Z)$

利用协方差的性质, 可以推广得多个随机变量的线性组合的方差公式, 以三个为例:

$$\begin{aligned}\mathbb{D}(X+Y+Z) &= \mathbb{D}(X+Y)+\mathbb{D}(Z)+2\,\mathrm{Cov}(X+Y,Z)\\ &= \mathbb{D}(X)+\mathbb{D}(Y)+2\,\mathrm{Cov}(X,Y)+\mathbb{D}(Z)+2\,\mathrm{Cov}(X,Z)+2\,\mathrm{Cov}(Y,Z)\\ &= \mathbb{D}(X)+\mathbb{D}(Y)+\mathbb{D}(Z)+2\,\mathrm{Cov}(X,Y)+2\,\mathrm{Cov}(X,Z)+2\,\mathrm{Cov}(Y,Z)\end{aligned}$$

协方差的性质

例题 2

设二维随机变量 (X,Y) 的联合密度函数为

$$p(x,y)=\begin{cases}\frac{1}{3}(x+y), & 0<x<1, \quad 0<y<2,\\ 0, & \text{o.w.}\end{cases}$$

试求 $\mathbb{D}(2X-3Y+8)$.

协方差的性质

例题 2

设二维随机变量 (X,Y) 的联合密度函数为

$$p(x,y)=\begin{cases}\frac{1}{3}(x+y), & 0<x<1, \quad 0<y<2,\\ 0, & \text{o.w.}\end{cases}$$

试求 $\mathbb{D}(2X-3Y+8)$.

证明. 因为

$$\mathbb{D}\big(2X-3Y+8\big) \;=\; \mathbb{D}\big(2X\big)+\mathbb{D}\big(3Y\big)+2\,\mathbf{Cov}\big(2X,-3Y\big)$$

协方差的性质

例题 2

设二维随机变量 (X,Y) 的联合密度函数为

$$p(x,y)=\begin{cases}\frac{1}{3}(x+y), & 0<x<1, \quad 0<y<2,\\ 0, & \text{o.w.}\end{cases}$$

试求 $\mathbb{D}(2X-3Y+8)$.

证明. 因为

$$\begin{aligned}\mathbb{D}(2X-3Y+8) &= \mathbb{D}(2X)+\mathbb{D}(3Y)+2\,\mathbf{Cov}(2X,-3Y)\\ &= 4\mathbb{D}(X)+9\mathbb{D}(Y)-12\,\mathbf{Cov}(X,Y)\end{aligned}$$

协方差的性质

例题 2

设二维随机变量 (X,Y) 的联合密度函数为

$$p(x,y)=\begin{cases}\frac{1}{3}(x+y), & 0<x<1, \quad 0<y<2,\\ 0, & \text{o.w.}\end{cases}$$

试求 $\mathbb{D}(2X-3Y+8)$.

证明. 因为

$$\begin{aligned}\mathbb{D}(2X-3Y+8) &= \mathbb{D}(2X)+\mathbb{D}(3Y)+2\,\mathrm{Cov}(2X,-3Y)\\ &= 4\mathbb{D}(X)+9\mathbb{D}(Y)-12\,\mathrm{Cov}(X,Y)\end{aligned}$$

所以我们先要分别计算

$$\mathbb{E}(X),\ \mathbb{E}(X^2),\ \mathbb{E}(Y),\ \mathbb{E}(Y^2),\ \mathbb{E}(XY).$$

协方差的性质

证明 (续). 为此先计算两个边际密度函数.

$$p_X(x)=\int_0^2 \frac{1}{3}(x+y)\,dy=\frac{2}{3}(x+1),\quad 0<x<1,$$

$$p_Y(y)=\int_0^1 \frac{1}{3}(x+y)\,dx=\frac{1}{3}\left(\frac{1}{2}+y\right),\quad 0<y<2.$$

协方差的性质

证明 (续). 为此先计算两个边际密度函数.

$$p_X(x)=\int_0^2 \frac{1}{3}(x+y)\,dy=\frac{2}{3}(x+1),\quad 0<x<1,$$
$$p_Y(y)=\int_0^1 \frac{1}{3}(x+y)\,dx=\frac{1}{3}\left(\frac{1}{2}+y\right),\quad 0<y<2.$$

然后再计算

$$\begin{aligned}
\mathbb{E}(X) &= \int_0^1 \frac{2}{3}x(x+1)dx=\frac{5}{9}, & \mathbb{E}(X^2) &= \int_0^1 \frac{2}{3}x^2(x+1)dx=\frac{7}{18},\\
\mathbb{E}(Y) &= \int_0^2 \frac{1}{3}y\left(\frac{1}{2}+y\right)dy=\frac{11}{9}, & \mathbb{E}(Y^2) &= \int_0^2 \frac{1}{3}y^2\left(\frac{1}{2}+y\right)dy=\frac{16}{9}.
\end{aligned}$$

协方差的性质

证明 (续). 为此先计算两个边际密度函数.

$$p_X(x) = \int_0^2 \frac{1}{3}(x+y)\,dy = \frac{2}{3}(x+1), \quad 0 < x < 1,$$
$$p_Y(y) = \int_0^1 \frac{1}{3}(x+y)\,dx = \frac{1}{3}\left(\frac{1}{2}+y\right), \quad 0 < y < 2.$$

然后再计算

$$\mathbb{E}(X) = \int_0^1 \frac{2}{3}x(x+1)dx = \frac{5}{9}, \qquad \mathbb{E}(X^2) = \int_0^1 \frac{2}{3}x^2(x+1)dx = \frac{7}{18},$$
$$\mathbb{E}(Y) = \int_0^2 \frac{1}{3}y\left(\frac{1}{2}+y\right)dy = \frac{11}{9}, \quad \mathbb{E}(Y^2) = \int_0^2 \frac{1}{3}y^2\left(\frac{1}{2}+y\right)dy = \frac{16}{9}.$$

和

$$\mathbb{E}(XY) = \frac{1}{3}\int_0^1\int_0^2 xy(x+y)dydx = \frac{1}{3}\int_0^1 \left(2x^2+\frac{8}{3}x\right)dx = \frac{2}{3}$$

协方差的性质

证明 (续). 已经求得

$$\mathbb{E}(X)=\frac{5}{9},\ \mathbb{E}(X^2)=\frac{7}{18},\ \mathbb{E}(Y)=\frac{11}{9},\ \mathbb{E}(Y^2)=\frac{16}{9},\ \mathbb{E}(XY)=\frac{2}{3}.$$

协方差的性质

证明 (续). 已经求得

$$\mathbb{E}(X)=\frac{5}{9},\ \mathbb{E}(X^2)=\frac{7}{18},\ \mathbb{E}(Y)=\frac{11}{9},\ \mathbb{E}(Y^2)=\frac{16}{9},\ \mathbb{E}(XY)=\frac{2}{3}.$$

由此可以计算方差

$$\mathbb{D}(X)=\frac{7}{18}-\left(\frac{5}{9}\right)^2=\frac{13}{162},\quad \mathbb{D}(Y)=\frac{16}{9}-\left(\frac{11}{9}\right)^2=\frac{23}{81}.$$

协方差的性质

证明 (续). 已经求得

$$\mathbb{E}(X)=\frac{5}{9},\ \mathbb{E}(X^2)=\frac{7}{18},\ \mathbb{E}(Y)=\frac{11}{9},\ \mathbb{E}(Y^2)=\frac{16}{9},\ \mathbb{E}(XY)=\frac{2}{3}.$$

由此可以计算方差

$$\mathbb{D}(X)=\frac{7}{18}-\left(\frac{5}{9}\right)^2=\frac{13}{162},\quad \mathbb{D}(Y)=\frac{16}{9}-\left(\frac{11}{9}\right)^2=\frac{23}{81}.$$

和协方差

$$\mathrm{Cov}(X,Y)=\frac{2}{3}-\frac{5}{9}\times\frac{11}{9}=-\frac{1}{81}$$

协方差的性质

证明 (续). 已经求得

$$\mathbb{E}(X)=\frac{5}{9},\ \mathbb{E}(X^2)=\frac{7}{18},\ \mathbb{E}(Y)=\frac{11}{9},\ \mathbb{E}(Y^2)=\frac{16}{9},\ \mathbb{E}(XY)=\frac{2}{3}.$$

由此可以计算方差

$$\mathbb{D}(X)=\frac{7}{18}-\left(\frac{5}{9}\right)^2=\frac{13}{162},\quad \mathbb{D}(Y)=\frac{16}{9}-\left(\frac{11}{9}\right)^2=\frac{23}{81}.$$

和协方差

$$\mathrm{Cov}(X,Y)=\frac{2}{3}-\frac{5}{9}\times\frac{11}{9}=-\frac{1}{81}$$

代回原式得

$$\mathbb{D}\big(2X-3Y+8\big)=4\times\overbrace{\frac{13}{162}}^{\mathbb{D}(X)}+9\times\overbrace{\frac{23}{81}}^{\mathbb{D}(Y)}-12\times\overbrace{\left(-\frac{1}{81}\right)}^{\mathrm{Cov}(X,Y)}=\frac{245}{81}.$$

协方差和相关性

回顾

$$\mathbf{Cov}(X,Y) = \mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))).$$

协方差和相关性

回顾

$$\mathrm{Cov}(X,Y)=\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))).$$

可以看出, 它是

X 的偏差 “$X-\mathbb{E}(X)$” 与 Y 的偏差 “$Y-\mathbb{E}(Y)$” 乘积的数学期望.

由于偏差可正可负, 故协方差也可正可负, 也可为零:

协方差和相关性

回顾

$$\mathrm{Cov}(X,Y)=\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))).$$

可以看出, 它是

X 的偏差 “$X-\mathbb{E}(X)$” 与 Y 的偏差 “$Y-\mathbb{E}(Y)$” 乘积的数学期望.

由于偏差可正可负, 故协方差也可正可负, 也可为零:

- 当 $\mathrm{Cov}(X,Y)>0$ 时, 称 X 与 Y 正相关, 这时 X 和 Y 有同时增或减的倾向.

协方差和相关性

回顾

$$\mathrm{Cov}(X,Y)=\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))).$$

可以看出, 它是

X 的偏差 “$X-\mathbb{E}(X)$” 与 Y 的偏差 “$Y-\mathbb{E}(Y)$” 乘积的数学期望.

由于偏差可正可负, 故协方差也可正可负, 也可为零:

- 当 $\mathrm{Cov}(X,Y)>0$ 时, 称 X 与 Y 正相关, 这时 X 和 Y 有同时增或减的倾向.
- 当 $\mathrm{Cov}(X,Y)<0$ 时, 称 X 与 Y 负相关, 这时有 X 增而 Y 减或有 Y 增而 X 减的倾向.

协方差和相关性

回顾

$$\mathrm{Cov}(X,Y)=\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))).$$

可以看出, 它是

X 的偏差 “$X-\mathbb{E}(X)$” 与 Y 的偏差 “$Y-\mathbb{E}(Y)$” 乘积的数学期望.

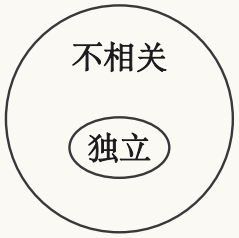
由于偏差可正可负, 故协方差也可正可负, 也可为零:

- 当 $\mathrm{Cov}(X,Y)>0$ 时, 称 X 与 Y 正相关, 这时 X 和 Y 有同时增或减的倾向.
- 当 $\mathrm{Cov}(X,Y)<0$ 时, 称 X 与 Y 负相关, 这时有 X 增而 Y 减或有 Y 增而 X 减的倾向.
- 当 $\mathrm{Cov}(X,Y)=0$ 时, 称 X 与 Y 不相关. 这时可能由两类情况导致: 一类是 X 与 Y 独立, 另一类是 X 与 Y 间存有某种**非线性关系**.

相关性与独立性

定理 5

若 X 和 Y 独立, 则 $\mathrm{Cov}(X, Y) = 0$; 反之不然.



相关性与独立性

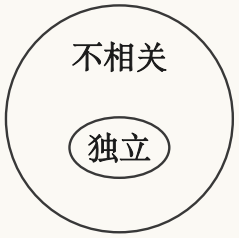
定理 5

若 X 和 Y 独立, 则 $\mathrm{Cov}(X,Y)=0$; 反之不然.

证明. 根据独立性和数学期望的定义, 有

$$\mathbb{E}(XY)=\mathbb{E}(X)\mathbb{E}(Y) \implies \mathrm{Cov}(X,Y)=0$$

定理的第一部分得证.



相关性与独立性

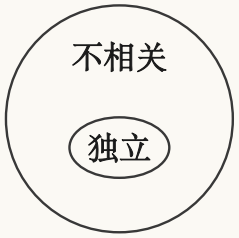
定理 5

若 X 和 Y 独立, 则 $\mathrm{Cov}(X,Y)=0$; 反之不然.

证明. 根据独立性和数学期望的定义, 有

$$\mathbb{E}(XY)=\mathbb{E}(X)\mathbb{E}(Y) \implies \mathrm{Cov}(X,Y)=0$$

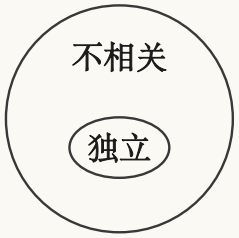
定理的第一部分得证. 下面用反例说明反之不然. 设 X 等可能地取值 $-1,0,1$, 令 $Y=X^2$,



相关性与独立性

定理 5

若 X 和 Y 独立, 则 $\mathrm{Cov}(X,Y)=0$; 反之不然.



证明. 根据独立性和数学期望的定义, 有

$$\mathbb{E}(XY)=\mathbb{E}(X)\mathbb{E}(Y) \Longrightarrow \mathrm{Cov}(X,Y)=0$$

定理的第一部分得证. 下面用反例说明反之不然. 设 X 等可能地取值 $-1,0,1$, 令 $Y=X^2$, 则

$$\mathbb{E}(X)=0, \qquad \mathbb{E}(XX^2)=\mathbb{E}(X^3)=0,$$

从而

$$\mathrm{Cov}(X,Y)=\mathbb{E}(XX^2)-\mathbb{E}(X)\mathbb{E}(X^2)=0.$$

但是

$$P\{X=1,Y=0\}=0\neq\frac{1}{9}=P\{X=1\}P\{Y=0\},$$

故 X 与 Y 不独立. 实际上, Y 由 X 完全决定.

相关性与独立性

定理针对一般性的情形; 我们可以找到一些特殊情况, 使得不相关等价于独立.

例题 3

设 A, B 是两个事件, 定义随机变量 X, Y. 证明 X 和 Y 不相关 $\Leftrightarrow$ A 和 B 独立.

$$X=\begin{cases}1 & \text{A发生}\\ -1 & \text{A不发生}\end{cases},\qquad Y=\begin{cases}1 & \text{B发生}\\ -1 & \text{B不发生}\end{cases}$$

相关性与独立性

定理针对一般性的情形; 我们可以找到一些特殊情况, 使得不相关等价于独立.

例题 3

设 A, B 是两个事件, 定义随机变量 X, Y. 证明 X 和 Y 不相关 $\Leftrightarrow$ A 和 B 独立.

$$X = \begin{cases} 1 & A\text{发生} \\ -1 & A\text{不发生} \end{cases}, \qquad Y = \begin{cases} 1 & B\text{发生} \\ -1 & B\text{不发生} \end{cases}$$

证明. 我们利用公式

$$\mathrm{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

来建立 $\mathrm{Cov}(X, Y)$ 与 $P(AB) - P(A)P(B)$ 的关系.

相关性与独立性

定理针对一般性的情形; 我们可以找到一些特殊情况, 使得不相关等价于独立.

例题 3

设 A, B 是两个事件, 定义随机变量 X, Y. 证明 X 和 Y 不相关 $\Leftrightarrow$ A 和 B 独立.

$$X = \begin{cases} 1 & A\text{发生} \\ -1 & A\text{不发生} \end{cases}, \qquad Y = \begin{cases} 1 & B\text{发生} \\ -1 & B\text{不发生} \end{cases}$$

证明. 我们利用公式

$$\mathrm{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

来建立 $\mathrm{Cov}(X, Y)$ 与 $P(AB) - P(A)P(B)$ 的关系. 首先, 根据期望的定义和 X, Y 的定义容易求得

$$\begin{aligned} \mathbb{E}(X) &= P(A) - P(\overline{A}) = 2P(A) - 1 \\ \mathbb{E}(Y) &= P(B) - P(\overline{B}) = 2P(B) - 1 \end{aligned}$$

相关性与独立性

证明 (续). 由

$$X=\begin{cases}1 & \text{A发生}\\ -1 & \text{A不发生}\end{cases},\qquad Y=\begin{cases}1 & \text{B发生}\\ -1 & \text{B不发生}\end{cases}$$

相关性与独立性

证明 (续). 由

$$X=\begin{cases}1 & A发生\\ -1 & A不发生\end{cases},\qquad Y=\begin{cases}1 & B发生\\ -1 & B不发生\end{cases}$$

可以计算

$$\mathbb{E}(XY) = \sum_{x,y\in\{1,-1\}} xyP\{X=x,Y=y\}$$

相关性与独立性

证明 (续). 由

$$X=\begin{cases}1 & A发生\\ -1 & A不发生\end{cases},\qquad Y=\begin{cases}1 & B发生\\ -1 & B不发生\end{cases}$$

可以计算

$$\begin{aligned}\mathbb{E}(XY) &= \sum_{x,y\in\{1,-1\}} xyP\{X=x,Y=y\}\\ &= P(AB)-P(A\overline{B})-P(\overline{A}B)+P(\overline{A\cup B})\end{aligned}$$

相关性与独立性

证明 (续). 由

$$X=\begin{cases}1 & A发生\\ -1 & A不发生\end{cases},\qquad Y=\begin{cases}1 & B发生\\ -1 & B不发生\end{cases}$$

可以计算

$$\begin{aligned}\mathbb{E}(XY) &= \sum_{x,y\in\{1,-1\}} xyP\{X=x,Y=y\}\\ &= P(AB)-P(A\overline{B})-P(\overline{A}B)+P(\overline{AB})\\ &= P(AB)-(P(A)-P(AB))-(P(B)-P(AB))+(1-P(A\cup B))\end{aligned}$$

相关性与独立性

证明 (续). 由

$$X=\begin{cases}1 & A发生\\ -1 & A不发生\end{cases},\qquad Y=\begin{cases}1 & B发生\\ -1 & B不发生\end{cases}$$

可以计算

$$\begin{aligned}\mathbb{E}(XY) &= \sum_{x,y\in\{1,-1\}} xyP\{X=x,Y=y\}\\ &= P(AB)-P(A\overline{B})-P(\overline{A}B)+P(\overline{AB})\\ &= P(AB)-(P(A)-P(AB))-(P(B)-P(AB))+(1-P(A\cup B))\\ &= 4P(AB)-2P(A)-2P(B)+1\end{aligned}$$

相关性与独立性

证明 (续). 由

$$X=\begin{cases}1 & A发生\\ -1 & A不发生\end{cases},\qquad Y=\begin{cases}1 & B发生\\ -1 & B不发生\end{cases}$$

可以计算

$$\begin{aligned}\mathbb{E}(XY) &= \sum_{x,y\in\{1,-1\}} xyP\{X=x,Y=y\}\\ &= P(AB)-P(A\overline{B})-P(\overline{A}B)+P(\overline{AB})\\ &= P(AB)-(P(A)-P(AB))-(P(B)-P(AB))+(1-P(A\cup B))\\ &= 4P(AB)-2P(A)-2P(B)+1\end{aligned}$$

由 $\mathbb{E}(X)=2P(A)-1, \mathbb{E}(Y)=2P(B)-1$, 可以计算

$$Cov(X,Y)=\mathbb{E}(XY)-\mathbb{E}(X)\mathbb{E}(Y)=4P(AB)-4P(A)P(B).$$

相关性与独立性

证明 (续). 由

$$X=\begin{cases}1 & A发生\\ -1 & A不发生\end{cases},\qquad Y=\begin{cases}1 & B发生\\ -1 & B不发生\end{cases}$$

可以计算

$$\begin{aligned}\mathbb{E}(XY) &= \sum_{x,y\in\{1,-1\}} xyP\{X=x,Y=y\}\\ &= P(AB)-P(A\overline{B})-P(\overline{A}B)+P(\overline{AB})\\ &= P(AB)-(P(A)-P(AB))-(P(B)-P(AB))+(1-P(A\cup B))\\ &= 4P(AB)-2P(A)-2P(B)+1\end{aligned}$$

由 $\mathbb{E}(X)=2P(A)-1, \mathbb{E}(Y)=2P(B)-1$, 可以计算

$$Cov(X,Y)=\mathbb{E}(XY)-\mathbb{E}(X)\mathbb{E}(Y)=4P(AB)-4P(A)P(B).$$

显然有 $Cov(X,Y)=0\Longleftrightarrow P(AB)=P(A)P(B)$.

相关系数

回顾 协方差刻画了随机变量 X 和 Y 的关联性:

- 当 $Cov(X,Y)>0$ 时, X 与 Y 正相关;
- 当 $Cov(X,Y)<0$ 时, X 与 Y 负相关;
- 当 $Cov(X,Y)=0$ 时, X 与 Y 不相关;

相关系数

回顾 协方差刻画了随机变量 X 和 Y 的关联性:

- 当 $\mathrm{Cov}(X,Y)>0$ 时, X 与 Y 正相关;
- 当 $\mathrm{Cov}(X,Y)<0$ 时, X 与 Y 负相关;
- 当 $\mathrm{Cov}(X,Y)=0$ 时, X 与 Y 不相关;

协方差 $\mathrm{Cov}(X,Y)$ 是有量纲的量. 譬如,

- X 表示人的身高, 单位是米 (m);
- Y 表示人的体重, 单位是千克 (kg);
- $\mathrm{Cov}(X,Y)$ 带有量纲 (m·kg).

相关系数

回顾 协方差刻画了随机变量 X 和 Y 的关联性:

- 当 $\mathrm{Cov}(X,Y)>0$ 时, X 与 Y 正相关;
- 当 $\mathrm{Cov}(X,Y)<0$ 时, X 与 Y 负相关;
- 当 $\mathrm{Cov}(X,Y)=0$ 时, X 与 Y 不相关;

协方差 $\mathrm{Cov}(X,Y)$ 是有量纲的量. 譬如,

- X 表示人的身高, 单位是米 (m);
- Y 表示人的体重, 单位是千克 (kg);
- $\mathrm{Cov}(X,Y)$ 带有量纲 (m·kg).

不同协方差之间是无法比较的.

相关系数

回顾 协方差刻画了随机变量 X 和 Y 的关联性:

- 当 $\mathrm{Cov}(X,Y)>0$ 时, X 与 Y 正相关;
- 当 $\mathrm{Cov}(X,Y)<0$ 时, X 与 Y 负相关;
- 当 $\mathrm{Cov}(X,Y)=0$ 时, X 与 Y 不相关;

协方差 $\mathrm{Cov}(X,Y)$ 是有量纲的量. 譬如,

- X 表示人的身高, 单位是米 (m);
- Y 表示人的体重, 单位是千克 (kg);
- $\mathrm{Cov}(X,Y)$ 带有量纲 (m·kg).

不同协方差之间是无法比较的. 为了消除量纲的影响, 对协方差除以相同量纲的量, 就得到一个新的概念——**相关系数**.

相关系数

定义 6

我们定义随机变量 X 与 Y 的相关系数为

$$\rho_{XY} = \frac{\mathbb{C}ov(X,Y)}{\sqrt{\mathbb{D}(X)}\sqrt{\mathbb{D}(Y)}}$$

若 $\rho_{XY} = 0$, 则称 X 和 Y(线性) 不相关. ρ_{XY} 是无量纲的量.

相关系数

定义 6

我们定义随机变量 X 与 Y 的相关系数为

$$\rho_{XY} = \frac{\mathbf{Cov}(X,Y)}{\sqrt{\mathbb{D}(X)}\sqrt{\mathbb{D}(Y)}}$$

若 $\rho_{XY} = 0$, 则称 X 和 Y(线性) 不相关. ρ_{XY} 是无量纲的量.

相关系数是相应标准化变量的协方差. 记 X 与 Y 的标准化变量为

$$X^* = \frac{X - \mathbb{E}(X)}{\sqrt{\mathbb{D}(X)}}, \quad Y^* = \frac{Y - \mathbb{E}(Y)}{\sqrt{\mathbb{D}(Y)}},$$

则有 $\mathbb{E}(X^*) = \mathbb{E}(Y^*) = 0, \mathbb{D}(X^*) = \mathbb{D}(Y^*) = 1$ (见课本 p101). 并且我们有

相关系数

定义 6

我们定义随机变量 X 与 Y 的相关系数为

$$\rho_{XY} = \frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathbb{D}(X)}\sqrt{\mathbb{D}(Y)}}$$

若 $\rho_{XY} = 0$, 则称 X 和 Y(线性) 不相关. ρ_{XY} 是无量纲的量.

相关系数是相应标准化变量的协方差. 记 X 与 Y 的标准化变量为

$$X^* = \frac{X - \mathbb{E}(X)}{\sqrt{\mathbb{D}(X)}}, \quad Y^* = \frac{Y - \mathbb{E}(Y)}{\sqrt{\mathbb{D}(Y)}},$$

则有 $\mathbb{E}(X^*) = \mathbb{E}(Y^*) = 0, \mathbb{D}(X^*) = \mathbb{D}(Y^*) = 1$ (见课本 p101). 并且我们有

$$\mathrm{Cov}(X^*, Y^*) = \mathrm{Cov}\left(\frac{X - \mathbb{E}(X)}{\sqrt{\mathbb{D}(X)}}, \frac{Y - \mathbb{E}(Y)}{\sqrt{\mathbb{D}(Y)}}\right) = \frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathbb{D}(X)}\sqrt{\mathbb{D}(Y)}} = \rho_{XY}.$$

相关系数

定义 6

我们定义随机变量 X 与 Y 的相关系数为

$$\rho_{XY} = \frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathbb{D}(X)}\sqrt{\mathbb{D}(Y)}}$$

若 $\rho_{XY} = 0$, 则称 X 和 Y(线性) 不相关. ρ_{XY} 是无量纲的量.

相关系数是相应标准化变量的协方差. 记 X 与 Y 的标准化变量为

$$X^* = \frac{X - \mathbb{E}(X)}{\sqrt{\mathbb{D}(X)}}, \quad Y^* = \frac{Y - \mathbb{E}(Y)}{\sqrt{\mathbb{D}(Y)}},$$

则有 $\mathbb{E}(X^*) = \mathbb{E}(Y^*) = 0, \mathbb{D}(X^*) = \mathbb{D}(Y^*) = 1$ (见课本 p101). 并且我们有

$$\mathrm{Cov}(X^*, Y^*) = \mathrm{Cov}\left(\frac{X - \mathbb{E}(X)}{\sqrt{\mathbb{D}(X)}}, \frac{Y - \mathbb{E}(Y)}{\sqrt{\mathbb{D}(Y)}}\right) = \frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathbb{D}(X)}\sqrt{\mathbb{D}(Y)}} = \rho_{XY}.$$

令 a, b, c 为常数, X 为随机变量, 上面的推导用到结论:

$$\mathrm{Cov}(a,b) = \mathbb{E}(ab) - \mathbb{E}(a)\mathbb{E}(b) = 0, \quad \mathrm{Cov}(X,c) = \mathbb{E}(cX) - \mathbb{E}(c)\mathbb{E}(X) = 0.$$

相关系数

我们接下来讨论相关系数的基本性质. 为此, 我们先给出一个引理.

引理 7 (施瓦茨 (Schwarz) 不等式)

对任意二维随机变量 (X, Y), 若 X 与 Y 的方差都存在, 则有

$$(\mathrm{Cov}(X, Y))^2 \leqslant \mathbb{D}(X)\mathbb{D}(Y).$$

相关系数

我们接下来讨论相关系数的基本性质. 为此, 我们先给出一个引理.

引理 7 (施瓦茨 (Schwarz) 不等式)

对任意二维随机变量 (X, Y), 若 X 与 Y 的方差都存在, 则有

$$(\mathrm{Cov}(X, Y))^2 \leqslant \mathbb{D}(X)\mathbb{D}(Y).$$

证明. 当 $\mathbb{D}(X) = 0$ 时, 则 X 几乎处处为常数, 因而其与 Y 的协方差亦为零, 从而上式两端皆为零, 结论成立.

相关系数

我们接下来讨论相关系数的基本性质. 为此, 我们先给出一个引理.

引理 7 (施瓦茨 (Schwarz) 不等式)

对任意二维随机变量 (X, Y), 若 X 与 Y 的方差都存在, 则有

$$(\mathrm{Cov}(X, Y))^2 \leqslant \mathbb{D}(X)\mathbb{D}(Y).$$

证明. 当 $\mathbb{D}(X) = 0$ 时, 则 X 几乎处处为常数, 因而其与 Y 的协方差亦为零, 从而上式两端皆为零, 结论成立. 若 $\mathbb{D}(X) > 0$ 成立, 考虑 t 的如下二次函数:

$$g(t) = \mathbb{E}[t(X - \mathbb{E}(X)) + (Y - \mathbb{E}(Y))]^2 = t^2\mathbb{D}(X) + 2t \cdot \mathrm{Cov}(X, Y) + \mathbb{D}(Y).$$

相关系数

我们接下来讨论相关系数的基本性质. 为此, 我们先给出一个引理.

引理 7 (施瓦茨 (Schwarz) 不等式)

对任意二维随机变量 (X, Y), 若 X 与 Y 的方差都存在, 则有

$$(\mathrm{Cov}(X, Y))^2 \leqslant \mathbb{D}(X)\mathbb{D}(Y).$$

证明. 当 $\mathbb{D}(X) = 0$ 时, 则 X 几乎处处为常数, 因而其与 Y 的协方差亦为零, 从而上式两端皆为零, 结论成立. 若 $\mathbb{D}(X) > 0$ 成立, 考虑 t 的如下二次函数:

$$g(t) = \mathbb{E}[t(X - \mathbb{E}(X)) + (Y - \mathbb{E}(Y))]^2 = t^2\mathbb{D}(X) + 2t \cdot \mathrm{Cov}(X, Y) + \mathbb{D}(Y).$$

由 $g(t)$ 定义可知 $g(t) \geqslant 0$ 且 $\mathbb{D}(X) > 0$, 所以:

$$(2\,\mathrm{Cov}(X, Y))^2 - 4\mathbb{D}(X)\mathbb{D}(Y) \leqslant 0.$$

相关系数

我们接下来讨论相关系数的基本性质. 为此, 我们先给出一个引理.

引理 7 (施瓦茨 (Schwarz) 不等式)

对任意二维随机变量 (X, Y), 若 X 与 Y 的方差都存在, 则有

$$(\mathrm{Cov}(X, Y))^2 \leqslant \mathbb{D}(X)\mathbb{D}(Y).$$

证明. 当 $\mathbb{D}(X) = 0$ 时, 则 X 几乎处处为常数, 因而其与 Y 的协方差亦为零, 从而上式两端皆为零, 结论成立. 若 $\mathbb{D}(X) > 0$ 成立, 考虑 t 的如下二次函数:

$$g(t) = \mathbb{E}[t(X - \mathbb{E}(X)) + (Y - \mathbb{E}(Y))]^2 = t^2\mathbb{D}(X) + 2t \cdot \mathrm{Cov}(X, Y) + \mathbb{D}(Y).$$

由 $g(t)$ 定义可知 $g(t) \geqslant 0$ 且 $\mathbb{D}(X) > 0$, 所以:

$$(2\,\mathrm{Cov}(X, Y))^2 - 4\mathbb{D}(X)\mathbb{D}(Y) \leqslant 0.$$

注释　引理说明: $|\rho_{XY}| \leqslant 1$.

相关系数

定理 8

$$\rho_{XY}=\pm 1 \quad \Leftrightarrow \quad \exists a\neq 0, b,\ P\{Y=aX+b\}=1 \quad \text{且} \quad \rho_{XY}=\begin{cases} 1 & a>0 \\ -1 & a<0 \end{cases}$$

相关系数

定理 8

$$\rho_{XY}=\pm 1 \quad \Leftrightarrow \quad \exists a\neq 0, b,\ P\{Y=aX+b\}=1 \quad \text{且} \quad \rho_{XY}=\begin{cases} 1 & a>0 \\ -1 & a<0 \end{cases}$$

证明. 充分性 ($\Leftarrow$). 若 $Y=aX+b$, 则

$$\mathbb{D}(Y)=a^2\mathbb{D}(X), \quad \operatorname{Cov}(X,Y)=a\operatorname{Cov}(X,X)=a\mathbb{D}(X)$$

相关系数

定理 8

$$\rho_{XY}=\pm 1 \quad \Leftrightarrow \quad \exists a\neq 0, b,\ P\{Y=aX+b\}=1 \quad \text{且} \quad \rho_{XY}=\begin{cases} 1 & a>0 \\ -1 & a<0 \end{cases}$$

证明. 充分性 ($\Leftarrow$). 若 $Y=aX+b$, 则

$$\mathbb{D}(Y)=a^2\mathbb{D}(X), \quad \operatorname{Cov}(X,Y)=a\operatorname{Cov}(X,X)=a\mathbb{D}(X)$$

代入可得

$$\rho_{XY}=\frac{\operatorname{Cov}(X,Y)}{\sqrt{\mathbb{D}(X)}\sqrt{\mathbb{D}(Y)}}=\frac{a\mathbb{D}(X)}{|a|\mathbb{D}(X)}=\operatorname{sign}(a)=\begin{cases} 1, & a>0 \\ -1, & a<0 \end{cases}$$

相关系数

定理 9

$$\rho_{XY}=\pm 1 \quad \Leftrightarrow \quad \exists a\neq 0, b,\ P\{Y=aX+b\}=1 \quad \text{且} \quad \rho_{XY}=\begin{cases} 1 & a>0 \\ -1 & a<0 \end{cases}$$

相关系数

定理 9

$$\rho_{XY}=\pm 1 \quad \Leftrightarrow \quad \exists a\neq 0, b,\ P\{Y=aX+b\}=1 \quad \text{且} \quad \rho_{XY}=\begin{cases} 1 & a>0 \\ -1 & a<0 \end{cases}$$

证明 (续). 必要性 ($\Rightarrow$). 我们仅考虑 $\rho_{XY}=1$ 的情形. 因为

$$\mathbb{D}\left(\frac{X}{\sqrt{\mathbb{D}(X)}}-\frac{Y}{\sqrt{\mathbb{D}(Y)}}\right)=\underbrace{\mathbb{D}\left(\frac{X}{\sqrt{\mathbb{D}(X)}}\right)}_{=1}+\underbrace{\mathbb{D}\left(\frac{Y}{\sqrt{\mathbb{D}(Y)}}\right)}_{=1}-2\underbrace{\operatorname{Cov}\left(\frac{X}{\sqrt{\mathbb{D}(X)}},\frac{Y}{\sqrt{\mathbb{D}(Y)}}\right)}_{=\rho_{XY}=1},$$

相关系数

定理 9

$$\rho_{XY}=\pm 1 \quad \Leftrightarrow \quad \exists a\neq 0, b,\ P\{Y=aX+b\}=1 \quad \text{且} \quad \rho_{XY}=\begin{cases} 1 & a>0 \\ -1 & a<0 \end{cases}$$

证明 (续). 必要性 ($\Rightarrow$). 我们仅考虑 $\rho_{XY}=1$ 的情形. 因为

$$\mathbb{D}\left(\frac{X}{\sqrt{\mathbb{D}(X)}}-\frac{Y}{\sqrt{\mathbb{D}(Y)}}\right)=\underbrace{\mathbb{D}\left(\frac{X}{\sqrt{\mathbb{D}(X)}}\right)}_{=1}+\underbrace{\mathbb{D}\left(\frac{Y}{\sqrt{\mathbb{D}(Y)}}\right)}_{=1}-2\underbrace{\operatorname{Cov}\left(\frac{X}{\sqrt{\mathbb{D}(X)}},\frac{Y}{\sqrt{\mathbb{D}(Y)}}\right)}_{=\rho_{XY}=1},$$

此时有

$$\mathbb{D}\left(\frac{X}{\sqrt{\mathbb{D}(X)}}-\frac{Y}{\sqrt{\mathbb{D}(Y)}}\right)=0 \implies P\left\{\frac{X}{\sqrt{\mathbb{D}(X)}}-\frac{Y}{\sqrt{\mathbb{D}(Y)}}=c\right\}=1$$

相关系数

定理 9

$$\rho_{XY}=\pm 1 \quad \Leftrightarrow \quad \exists a\neq 0, b,\ P\{Y=aX+b\}=1 \quad \text{且} \quad \rho_{XY}=\begin{cases} 1 & a>0 \\ -1 & a<0 \end{cases}$$

证明 (续). 必要性 ($\Rightarrow$). 我们仅考虑 $\rho_{XY}=1$ 的情形. 因为

$$\mathbb{D}\left(\frac{X}{\sqrt{\mathbb{D}(X)}}-\frac{Y}{\sqrt{\mathbb{D}(Y)}}\right)=\underbrace{\mathbb{D}\left(\frac{X}{\sqrt{\mathbb{D}(X)}}\right)}_{=1}+\underbrace{\mathbb{D}\left(\frac{Y}{\sqrt{\mathbb{D}(Y)}}\right)}_{=1}-2\underbrace{\operatorname{Cov}\left(\frac{X}{\sqrt{\mathbb{D}(X)}},\frac{Y}{\sqrt{\mathbb{D}(Y)}}\right)}_{=\rho_{XY}=1},$$

此时有

$$\mathbb{D}\left(\frac{X}{\sqrt{\mathbb{D}(X)}}-\frac{Y}{\sqrt{\mathbb{D}(Y)}}\right)=0 \implies P\left\{\frac{X}{\sqrt{\mathbb{D}(X)}}-\frac{Y}{\sqrt{\mathbb{D}(Y)}}=c\right\}=1$$

$$\implies P\left\{Y=\underbrace{\frac{\sqrt{\mathbb{D}(Y)}}{\sqrt{\mathbb{D}(X)}}}_{a}X\underbrace{-c\sqrt{\mathbb{D}(Y)}}_{b}\right\}=1.$$

相关系数

回顾 我们已经证明

- $|\rho_{XY}| \leqslant 1$;
- $\rho_{XY} = \pm 1 \Leftrightarrow \exists a \neq 0, b, P\{Y = aX + b\} = 1$. 其中 $\rho_{XY} = \operatorname{sign}(a)$.

可见 ρ_{XY} 刻画了 X 与 Y 的线性关系强弱, 因此也常被称为线性相关系数.

相关系数

回顾 我们已经证明

- $|\rho_{XY}| \leqslant 1$;
- $\rho_{XY} = \pm 1 \Leftrightarrow \exists a \neq 0, b, P\{Y = aX + b\} = 1$. 其中 $\rho_{XY} = \operatorname{sign}(a)$.

可见 ρ_{XY} 刻画了 X 与 Y 的线性关系强弱, 因此也常被称为线性相关系数.

- 若 $\rho_{XY} = 0$, 则称 X 与 Y 不相关——X 与 Y 之间没有线性关系, 但 X 与 Y 之间可能有其他的函数关系, 譬如平方关系, 对数关系等;

相关系数

回顾 我们已经证明

- $|\rho_{XY}| \leqslant 1$;
- $\rho_{XY} = \pm 1 \Leftrightarrow \exists a \neq 0, b, P\{Y = aX + b\} = 1$. 其中 $\rho_{XY} = \operatorname{sign}(a)$.

可见 ρ_{XY} 刻画了 X 与 Y 的线性关系强弱, 因此也常被称为线性相关系数.

- 若 $\rho_{XY} = 0$, 则称 X 与 Y 不相关——X 与 Y 之间没有线性关系, 但 X 与 Y 之间可能有其他的函数关系, 譬如平方关系, 对数关系等;
- 若 $\rho_{XY} = 1$, 则称 X 与 Y 完全正相关;

相关系数

回顾 我们已经证明

- $|\rho_{XY}| \leqslant 1$;
- $\rho_{XY} = \pm 1 \Leftrightarrow \exists a \neq 0, b, P\{Y = aX + b\} = 1$. 其中 $\rho_{XY} = \operatorname{sign}(a)$.

可见 ρ_{XY} 刻画了 X 与 Y 的线性关系强弱, 因此也常被称为线性相关系数.

- 若 $\rho_{XY} = 0$, 则称 X 与 Y 不相关——X 与 Y 之间没有线性关系, 但 X 与 Y 之间可能有其他的函数关系, 譬如平方关系, 对数关系等;
- 若 $\rho_{XY} = 1$, 则称 X 与 Y 完全正相关;
- 若 $\rho_{XY} = -1$, 则称 X 与 Y 完全负相关;

相关系数

回顾 我们已经证明

- $|\rho_{XY}| \leqslant 1$;
- $\rho_{XY} = \pm 1 \Leftrightarrow \exists a \neq 0, b, P\{Y = aX + b\} = 1$. 其中 $\rho_{XY} = \operatorname{sign}(a)$.

可见 ρ_{XY} 刻画了 X 与 Y 的线性关系强弱, 因此也常被称为线性相关系数.

- 若 $\rho_{XY} = 0$, 则称 X 与 Y 不相关——X 与 Y 之间没有线性关系, 但 X 与 Y 之间可能有其他的函数关系, 譬如平方关系, 对数关系等;
- 若 $\rho_{XY} = 1$, 则称 X 与 Y 完全正相关;
- 若 $\rho_{XY} = -1$, 则称 X 与 Y 完全负相关;
- 若 $0 < |\rho_{XY}| < 1$, 则称 X 与 Y 有 “一定程度” 的线性关系. $|\rho_{XY}|$ 越接近于 1, 则线性相关度越高; $|\rho_{XY}|$ 越接近于 0, 则线性相关度越低.**协方差看不出这一点: 若协方差很小, 两个标准差也很小, 则比值不一定小.**

相关系数

例题 4

设 X, Y 是两个随机变量且有如下参数. 设 $U = X - 2Y$, $V = 2X - Y$. 求: ρ_{UV}.

$$\mathbb{D}(X) = 1, \quad \mathbb{D}(Y) = 4, \quad \mathrm{Cov}(X, Y) = 1.$$

相关系数

例题 4

设 X, Y 是两个随机变量且有如下参数. 设 $U = X - 2Y$, $V = 2X - Y$. 求: ρ_{UV}.

$$\mathbb{D}(X) = 1, \quad \mathbb{D}(Y) = 4, \quad \mathrm{Cov}(X, Y) = 1.$$

证明. 利用方差的性质可以计算:

$$\begin{aligned} \mathbb{D}(U) &= \mathbb{D}(X - 2Y) = \mathbb{D}(X) + 4\mathbb{D}(Y) - 4\,\mathrm{Cov}(X, Y) = 13 \\ \mathbb{D}(V) &= \mathbb{D}(2X - Y) = 4\mathbb{D}(X) + \mathbb{D}(Y) - 4\,\mathrm{Cov}(X, Y) = 4 \end{aligned}$$

相关系数

例题 4

设 X, Y 是两个随机变量且有如下参数. 设 $U = X - 2Y$, $V = 2X - Y$. 求: ρ_{UV}.

$$\mathbb{D}(X) = 1, \quad \mathbb{D}(Y) = 4, \quad \mathrm{Cov}(X, Y) = 1.$$

证明. 利用方差的性质可以计算:

$$\begin{aligned} \mathbb{D}(U) &= \mathbb{D}(X - 2Y) = \mathbb{D}(X) + 4\mathbb{D}(Y) - 4\,\mathrm{Cov}(X, Y) = 13 \\ \mathbb{D}(V) &= \mathbb{D}(2X - Y) = 4\mathbb{D}(X) + \mathbb{D}(Y) - 4\,\mathrm{Cov}(X, Y) = 4 \end{aligned}$$

利用协方差的性质可以计算:

$$\mathrm{Cov}(U, V) = \mathrm{Cov}(X - 2Y, 2X - Y)$$

相关系数

例题 4

设 X, Y 是两个随机变量且有如下参数. 设 $U = X - 2Y$, $V = 2X - Y$. 求: ρ_{UV}.

$$\mathbb{D}(X) = 1, \quad \mathbb{D}(Y) = 4, \quad \mathrm{Cov}(X, Y) = 1.$$

证明. 利用方差的性质可以计算:

$$\begin{aligned} \mathbb{D}(U) &= \mathbb{D}(X - 2Y) = \mathbb{D}(X) + 4\mathbb{D}(Y) - 4\,\mathrm{Cov}(X, Y) = 13 \\ \mathbb{D}(V) &= \mathbb{D}(2X - Y) = 4\mathbb{D}(X) + \mathbb{D}(Y) - 4\,\mathrm{Cov}(X, Y) = 4 \end{aligned}$$

利用协方差的性质可以计算:

$$\begin{aligned} \mathrm{Cov}(U, V) &= \mathrm{Cov}(X - 2Y, 2X - Y) \\ &= 2\,\mathrm{Cov}(X, X) - 4\,\mathrm{Cov}(Y, X) - \mathrm{Cov}(X, Y) + 2\,\mathrm{Cov}(Y, Y) = 5 \end{aligned}$$

相关系数

例题 4

设 X,Y 是两个随机变量且有如下参数. 设 $U=X-2Y, V=2X-Y$. 求: ρ_{UV}.

$$\mathbb{D}(X)=1, \quad \mathbb{D}(Y)=4, \quad \mathrm{Cov}(X,Y)=1.$$

证明. 利用方差的性质可以计算:

$$\begin{aligned}\mathbb{D}(U) &= \mathbb{D}(X-2Y)=\mathbb{D}(X)+4\mathbb{D}(Y)-4\,\mathrm{Cov}(X,Y)=13\\ \mathbb{D}(V) &= \mathbb{D}(2X-Y)=4\mathbb{D}(X)+\mathbb{D}(Y)-4\,\mathrm{Cov}(X,Y)=4\end{aligned}$$

利用协方差的性质可以计算:

$$\begin{aligned}\mathrm{Cov}(U,V) &= \mathrm{Cov}(X-2Y,2X-Y)\\ &= 2\,\mathrm{Cov}(X,X)-4\,\mathrm{Cov}(Y,X)-\mathrm{Cov}(X,Y)+2\,\mathrm{Cov}(Y,Y)=5\end{aligned}$$

根据相关系数的定义可得: $\rho_{UV}=\dfrac{\mathrm{Cov}(U,V)}{\sqrt{\mathbb{D}(U)}\sqrt{\mathbb{D}(V)}}=\dfrac{5\sqrt{13}}{26}$.

案例: 二维正态分布的相关系数

回顾 随机变量 $(X,Y)\sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$, 其概率密度函数 $f(x,y)$ 为

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{\frac{-1}{2(1-\rho^2)}\left(\frac{(x-\mu_1)^2}{\sigma_1^2}-2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2}+\frac{(y-\mu_2)^2}{\sigma_2^2}\right)\right\}$$

其中 $\sigma_1,\sigma_2>0, -1<\rho<1$. 我们已经知道

$$\mathbb{E}(X)=\mu_1,\ \mathbb{D}(X)=\sigma_1^2,\ \mathbb{E}(Y)=\mu_2,\ \mathbb{D}(Y)=\sigma_2^2.$$

案例: 二维正态分布的相关系数

回顾 随机变量 $(X,Y)\sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$, 其概率密度函数 $f(x,y)$ 为

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{\frac{-1}{2(1-\rho^2)}\left(\frac{(x-\mu_1)^2}{\sigma_1^2}-2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2}+\frac{(y-\mu_2)^2}{\sigma_2^2}\right)\right\}$$

其中 $\sigma_1,\sigma_2>0,-1<\rho<1$. 我们已经知道

$$\mathbb{E}(X)=\mu_1,\ \mathbb{D}(X)=\sigma_1^2,\ \mathbb{E}(Y)=\mu_2,\ \mathbb{D}(Y)=\sigma_2^2.$$

按照定义, 我们计算

$$\mathrm{Cov}(X,Y)=\mathbb{E}(\overbrace{(X-\mathbb{E}(X))(Y-\mathbb{E}(Y))}^{g(X,Y)})=\iint_{\mathbb{R}^2}\frac{(x-\mu_1)(y-\mu_2)}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\{\blacksquare\}\,dx\,dy$$

案例: 二维正态分布的相关系数

回顾 随机变量 $(X,Y)\sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$, 其概率密度函数 $f(x,y)$ 为

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{\frac{-1}{2(1-\rho^2)}\left(\frac{(x-\mu_1)^2}{\sigma_1^2}-2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2}+\frac{(y-\mu_2)^2}{\sigma_2^2}\right)\right\}$$

其中 $\sigma_1,\sigma_2>0,-1<\rho<1$. 我们已经知道

$$\mathbb{E}(X)=\mu_1,\ \mathbb{D}(X)=\sigma_1^2,\ \mathbb{E}(Y)=\mu_2,\ \mathbb{D}(Y)=\sigma_2^2.$$

按照定义, 我们计算

$$\mathrm{Cov}(X,Y)=\mathbb{E}(\overbrace{(X-\mathbb{E}(X))(Y-\mathbb{E}(Y))}^{g(X,Y)})=\iint_{\mathbb{R}^2}\frac{(x-\mu_1)(y-\mu_2)}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\{\blacksquare\}\,dx\,dy$$

其中

$$\blacksquare=-\frac{(x-\mu_1)^2}{2\sigma_1^2}-\frac{1}{2(1-\rho^2)}\left(\rho\frac{x-\mu_1}{\sigma_1}-\frac{y-\mu_2}{\sigma_2}\right)^2$$

案例: 二维正态分布的相关系数

我们将指数部分进行配方:

$$\blacksquare = -\overbrace{\frac{(x-\mu_1)^2}{2\sigma_1^2}}^{u^2/2} - \overbrace{\frac{1}{2(1-\rho^2)}\left(\rho\frac{x-\mu_1}{\sigma_1} - \frac{y-\mu_2}{\sigma_2}\right)^2}^{v^2/2}$$

案例: 二维正态分布的相关系数

我们将指数部分进行配方:

$$\blacksquare = -\overbrace{\frac{(x-\mu_1)^2}{2\sigma_1^2}}^{u^2/2} - \overbrace{\frac{1}{2(1-\rho^2)}\left(\rho\frac{x-\mu_1}{\sigma_1} - \frac{y-\mu_2}{\sigma_2}\right)^2}^{v^2/2}$$

据此, 我们做如下的换元来简化被积函数:

$$\begin{cases} u = \dfrac{x-\mu_1}{\sigma_1} \\ v = \dfrac{1}{\sqrt{1-\rho^2}}\left(\rho\dfrac{x-\mu_1}{\sigma_1} - \dfrac{y-\mu_2}{\sigma_2}\right) \end{cases} \Longrightarrow \begin{cases} x-\mu_1 = \sigma_1 u \\ y-\mu_2 = \left(\rho u - v\sqrt{1-\rho^2}\right)\sigma_2. \end{cases}$$

案例: 二维正态分布的相关系数

我们将指数部分进行配方:

$$\blacksquare = -\overbrace{\frac{(x-\mu_1)^2}{2\sigma_1^2}}^{u^2/2} - \overbrace{\frac{1}{2(1-\rho^2)}\left(\rho\frac{x-\mu_1}{\sigma_1} - \frac{y-\mu_2}{\sigma_2}\right)^2}^{v^2/2}$$

据此, 我们做如下的换元来简化被积函数:

$$\begin{cases} u = \dfrac{x-\mu_1}{\sigma_1} \\ v = \dfrac{1}{\sqrt{1-\rho^2}}\left(\rho\dfrac{x-\mu_1}{\sigma_1} - \dfrac{y-\mu_2}{\sigma_2}\right) \end{cases} \Longrightarrow \begin{cases} x-\mu_1 = \sigma_1 u \\ y-\mu_2 = \left(\rho u - v\sqrt{1-\rho^2}\right)\sigma_2. \end{cases}$$

其所对应的雅可比行列式为

$$J(u,v) = \begin{vmatrix} \dfrac{\partial x}{\partial u} & \dfrac{\partial x}{\partial v} \\ \dfrac{\partial y}{\partial u} & \dfrac{\partial y}{\partial v} \end{vmatrix} = \begin{vmatrix} \sigma_1 & 0 \\ \rho & -\sqrt{1-\rho^2}\sigma_2 \end{vmatrix} = -\sigma_1\sigma_2\sqrt{1-\rho^2}$$

因为 $\sigma_1, \sigma_2 > 0$, 于是 $|J(u,v)| = \sigma_1\sigma_2\sqrt{1-\rho^2}$.

案例: 二维正态分布的相关系数

所以, 我们可以如下计算 $\mathrm{Cov}(X, Y)$:

$$\iint_{\mathbb{R}^2} \frac{\overbrace{\sigma_1 u}^{x-\mu_1} \cdot \overbrace{\sigma_2(\rho u - v\sqrt{1-\rho^2})}^{y-\mu_2}}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-u^2/2-v^2/2} \cdot \overbrace{\sigma_1\sigma_2\sqrt{1-\rho^2}}^{|J(u,v)|} \,\mathrm{d}u\,\mathrm{d}v$$

案例: 二维正态分布的相关系数

所以, 我们可以如下计算 $\mathrm{Cov}(X,Y)$:

$$\iint_{\mathbb{R}^2} \frac{\overbrace{\sigma_1 u}^{x-\mu_1} \cdot \overbrace{\sigma_2(\rho u - v\sqrt{1-\rho^2})}^{y-\mu_2}}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-u^2/2-v^2/2} \cdot \overbrace{\sigma_1\sigma_2\sqrt{1-\rho^2}}^{|J(u,v)|} \,\mathrm{d}u\,\mathrm{d}v$$

$$= \frac{\sigma_1\sigma_2\rho}{2\pi} \underbrace{\iint_{\mathbb{R}^2} u^2 e^{-u^2/2-v^2/2}\,\mathrm{d}u\,\mathrm{d}v}_{\sqrt{2\pi}\times\sqrt{2\pi}} - \frac{\sigma_1\sigma_2\sqrt{1-\rho^2}}{2\pi} \underbrace{\iint_{\mathbb{R}^2} uv e^{-u^2/2-v^2/2}\,\mathrm{d}u\,\mathrm{d}v}_{0\times 0}$$

案例: 二维正态分布的相关系数

所以, 我们可以如下计算 $\mathrm{Cov}(X,Y)$:

$$\iint_{\mathbb{R}^2} \frac{\overbrace{\sigma_1 u}^{x-\mu_1} \cdot \overbrace{\sigma_2(\rho u - v\sqrt{1-\rho^2})}^{y-\mu_2}}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-u^2/2-v^2/2} \cdot \overbrace{\sigma_1\sigma_2\sqrt{1-\rho^2}}^{|J(u,v)|} \,\mathrm{d}u\,\mathrm{d}v$$

$$= \frac{\sigma_1\sigma_2\rho}{2\pi} \underbrace{\iint_{\mathbb{R}^2} u^2 e^{-u^2/2-v^2/2}\,\mathrm{d}u\,\mathrm{d}v}_{\sqrt{2\pi}\times\sqrt{2\pi}} - \frac{\sigma_1\sigma_2\sqrt{1-\rho^2}}{2\pi} \underbrace{\iint_{\mathbb{R}^2} uv e^{-u^2/2-v^2/2}\,\mathrm{d}u\,\mathrm{d}v}_{0\times 0}$$

因而,

$$\rho_{XY} = \rho.$$

案例: 二维正态分布的相关系数

所以, 我们可以如下计算 $\mathrm{Cov}(X,Y)$:

$$\iint_{\mathbb{R}^2} \frac{\overbrace{\sigma_1 u}^{x-\mu_1} \cdot \overbrace{\sigma_2(\rho u - v\sqrt{1-\rho^2})}^{y-\mu_2}}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-u^2/2-v^2/2} \cdot \overbrace{\sigma_1\sigma_2\sqrt{1-\rho^2}}^{|J(u,v)|} \,\mathrm{d}u\,\mathrm{d}v$$

$$= \frac{\sigma_1\sigma_2\rho}{2\pi} \underbrace{\iint_{\mathbb{R}^2} u^2 e^{-u^2/2-v^2/2}\,\mathrm{d}u\,\mathrm{d}v}_{\sqrt{2\pi}\times\sqrt{2\pi}} - \frac{\sigma_1\sigma_2\sqrt{1-\rho^2}}{2\pi} \underbrace{\iint_{\mathbb{R}^2} uv e^{-u^2/2-v^2/2}\,\mathrm{d}u\,\mathrm{d}v}_{0\times 0}$$

因而,

$$\rho_{XY} = \rho.$$

注释 上述结果意味着:

- ▷ 二维正态分布由 X,Y 各自的数学期望、方差和相关系数确定.
- ▷ 对于二维正态分布来说, X,Y 相互独立等价于 X,Y 不相关.

矩

概念: 期望、方差、协方差的推广

定义 10

设 X 和 Y 是随机变量且以下的数字特征存在, 则定义

- X 的 k 阶原点矩, 或者 k 阶矩: $\mathbb{E}(X^k)$, $k = 1, 2, \ldots$;
- X 的 k 阶中心矩: $\mathbb{E}((X - \mathbb{E}(X))^k)$, $k = 1, 2, \ldots$;
- X 和 Y 的 $k+\ell$ 阶混合矩: $\mathbb{E}(X^k Y^\ell)$, $k, \ell = 1, 2, \ldots$;
- X 和 Y 的 $k+\ell$ 阶混合中心矩: $\mathbb{E}((X - \mathbb{E}(X))^k (Y - \mathbb{E}(Y))^\ell)$, $k, \ell = 1, 2, \ldots$.

概念: 期望、方差、协方差的推广

定义 10

设 X 和 Y 是随机变量且以下的数字特征存在, 则定义

- X 的 k 阶原点矩, 或者 k 阶矩: $\mathbb{E}(X^k)$, $k = 1, 2, \ldots$;
- X 的 k 阶中心矩: $\mathbb{E}((X - \mathbb{E}(X))^k)$, $k = 1, 2, \ldots$;
- X 和 Y 的 $k + \ell$ 阶混合矩: $\mathbb{E}(X^k Y^\ell)$, $k, \ell = 1, 2, \ldots$;
- X 和 Y 的 $k + \ell$ 阶混合中心矩: $\mathbb{E}((X - \mathbb{E}(X))^k (Y - \mathbb{E}(Y))^\ell)$, $k, \ell = 1, 2, \ldots$.

我们可以看到:

- X 的期望 $\mathbb{E}(X)$ 是一阶原点矩;
- X 的方差 $\mathbb{D}(X)$ 是二阶中心矩;
- X, Y 的协方差 $\mathrm{Cov}(X, Y)$ 是二阶混合中心矩.

概念: 期望、方差、协方差的推广

例题 5

设随机变量 $X \sim N(0, \sigma^2)$, 求 $\mathbb{E}(X^n)$.

概念: 期望、方差、协方差的推广

例题 5

设随机变量 $X \sim N(0, \sigma^2)$, 求 $\mathbb{E}(X^n)$.

证明. 定义 Y 是 X 的标准化变量, $Y = (X - \mathbb{E}(X))/\sqrt{\mathbb{D}(X)} = X/\sigma$, 则 $Y \sim N(0,1)$. 于是

$$\mathbb{E}(X^n) = \sigma^n \mathbb{E}(Y^n) = \frac{\sigma^n}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y^n e^{-y^2/2} \, dy.$$

概念: 期望、方差、协方差的推广

例题 5

设随机变量 $X \sim N(0, \sigma^2)$, 求 $\mathbb{E}(X^n)$.

证明. 定义 Y 是 X 的标准化变量, $Y = (X - \mathbb{E}(X))/\sqrt{\mathbb{D}(X)} = X/\sigma$, 则 $Y \sim N(0,1)$. 于是

$$\mathbb{E}(X^n) = \sigma^n \mathbb{E}(Y^n) = \frac{\sigma^n}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y^n e^{-y^2/2} \, dy.$$

若 n 是奇数, 则被积函数是奇函数, $\mathbb{E}(X^n) = 0$; 若 n 是偶数, 则被积函数是偶函数, 故

$$\mathbb{E}(X^n) = \frac{2\sigma^n}{\sqrt{2\pi}} \int_0^{\infty} y^n e^{-y^2/2} \, dy = \frac{2^{n/2}\sigma^n}{\sqrt{\pi}} \Gamma\left(\frac{n+1}{2}\right) = \sigma^n (n-1)!!.$$

概念: 期望、方差、协方差的推广

例题 5

设随机变量 $X \sim N(0, \sigma^2)$, 求 $\mathbb{E}(X^n)$.

证明. 定义 Y 是 X 的标准化变量, $Y = (X - \mathbb{E}(X))/\sqrt{\mathbb{D}(X)} = X/\sigma$, 则 $Y \sim N(0,1)$. 于是

$$\mathbb{E}(X^n) = \sigma^n \mathbb{E}(Y^n) = \frac{\sigma^n}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y^n e^{-y^2/2} \, dy.$$

若 n 是奇数, 则被积函数是奇函数, $\mathbb{E}(X^n) = 0$; 若 n 是偶数, 则被积函数是偶函数, 故

$$\mathbb{E}(X^n) = \frac{2\sigma^n}{\sqrt{2\pi}} \int_0^{\infty} y^n e^{-y^2/2} \, dy = \frac{2^{n/2}\sigma^n}{\sqrt{\pi}} \Gamma\left(\frac{n+1}{2}\right) = \sigma^n (n-1)!!.$$

第二步使用换元 $t = y^2/2$, 故 $y = \sqrt{2t}$, $dy = (2t)^{-\frac{1}{2}} \, dt$, 于是

$$\int_0^{\infty} y^n e^{-y^2/2} \, dy = \int_0^{\infty} (2t)^{\frac{n-1}{2}} e^{-t} \, dt = 2^{\frac{n-1}{2}} \int_0^{\infty} t^{\frac{n-1}{2}} e^{-t} \, dt = 2^{\frac{n-1}{2}} \Gamma\left(\frac{n+1}{2}\right).$$

概念: 期望、方差、协方差的推广

例题 5

设随机变量 $X \sim N(0, \sigma^2)$, 求 $\mathbb{E}(X^n)$.

证明. 定义 Y 是 X 的标准化变量, $Y = (X - \mathbb{E}(X))/\sqrt{\mathbb{D}(X)} = X/\sigma$, 则 $Y \sim N(0,1)$. 于是

$$\mathbb{E}(X^n) = \sigma^n \mathbb{E}(Y^n) = \frac{\sigma^n}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y^n e^{-y^2/2} \, dy.$$

若 n 是奇数, 则被积函数是奇函数, $\mathbb{E}(X^n) = 0$; 若 n 是偶数, 则被积函数是偶函数, 故

$$\mathbb{E}(X^n) = \frac{2\sigma^n}{\sqrt{2\pi}} \int_0^{\infty} y^n e^{-y^2/2} \, dy = \frac{2^{n/2}\sigma^n}{\sqrt{\pi}} \Gamma\left(\frac{n+1}{2}\right) = \sigma^n (n-1)!!.$$

第二步使用换元 $t = y^2/2$, 故 $y = \sqrt{2t}$, $dy = (2t)^{-\frac{1}{2}} \, dt$, 于是

$$\int_0^{\infty} y^n e^{-y^2/2} \, dy = \int_0^{\infty} (2t)^{\frac{n-1}{2}} e^{-t} \, dt = 2^{\frac{n-1}{2}} \int_0^{\infty} t^{\frac{n-1}{2}} e^{-t} \, dt = 2^{\frac{n-1}{2}} \Gamma\left(\frac{n+1}{2}\right).$$

第三步用到 Γ 的递推公式 $\Gamma(\alpha+1) = \alpha\Gamma(\alpha)$ 以及 $\Gamma(1/2) = \sqrt{\pi}$, 故

$$\Gamma\left(\frac{n+1}{2}\right) = \frac{n-1}{2} \cdot \frac{n-3}{2} \cdots \frac{1}{2} \cdot \Gamma\left(\frac{1}{2}\right) = \frac{(n-1)!!}{2^{n/2}} \sqrt{\pi}.$$

协方差矩阵

定义 11

设 (X_1, X_2) 的四个二阶混合中心矩存在, 记为

$$c_{11} = \mathbb{E}((X_1 - \mathbb{E}(X_1))^2), \qquad c_{12} = \mathbb{E}((X_1 - \mathbb{E}(X_1))(X_2 - \mathbb{E}(X_2)))$$
$$c_{21} = \mathbb{E}((X_2 - \mathbb{E}(X_2))(X_1 - \mathbb{E}(X_1))), \quad c_{22} = \mathbb{E}((X_2 - \mathbb{E}(X_2))^2)$$

我们称 $C = (c_{ij})_{i,j}$ 为随机变量 (X_1, X_2) 的*协方差矩阵*.

协方差矩阵

定义 11

设 (X_1, X_2) 的四个二阶混合中心矩存在, 记为

$$c_{11} = \mathbb{E}((X_1 - \mathbb{E}(X_1))^2), \qquad c_{12} = \mathbb{E}((X_1 - \mathbb{E}(X_1))(X_2 - \mathbb{E}(X_2)))$$
$$c_{21} = \mathbb{E}((X_2 - \mathbb{E}(X_2))(X_1 - \mathbb{E}(X_1))), \quad c_{22} = \mathbb{E}((X_2 - \mathbb{E}(X_2))^2)$$

我们称 $C = (c_{ij})_{i,j}$ 为随机变量 (X_1, X_2) 的*协方差矩阵*.

定义 12

设 n 维随机变量 $(X_1, X_2, \dots, X_n)$ 的二阶混合中心矩存在, 记

$$c_{ij} = \mathbb{E}((X_i - \mathbb{E}(X_i))(X_j - \mathbb{E}(X_j))), \quad i, j = 1, 2, \dots, n$$

我们称 $C = (c_{ij})_{i,j}$ 为随机变量 $(X_1, X_2, \dots, X_n)$ 的*协方差矩阵*.

协方差矩阵

定义 11

设 (X_1, X_2) 的四个二阶混合中心矩存在, 记为

$$c_{11} = \mathbb{E}((X_1 - \mathbb{E}(X_1))^2), \qquad c_{12} = \mathbb{E}((X_1 - \mathbb{E}(X_1))(X_2 - \mathbb{E}(X_2)))$$
$$c_{21} = \mathbb{E}((X_2 - \mathbb{E}(X_2))(X_1 - \mathbb{E}(X_1))), \quad c_{22} = \mathbb{E}((X_2 - \mathbb{E}(X_2))^2)$$

我们称 $C = (c_{ij})_{i,j}$ 为随机变量 (X_1, X_2) 的*协方差矩阵*.

定义 12

设 n 维随机变量 $(X_1, X_2, \dots, X_n)$ 的二阶混合中心矩存在, 记

$$c_{ij} = \mathbb{E}((X_i - \mathbb{E}(X_i))(X_j - \mathbb{E}(X_j))), \quad i, j = 1, 2, \dots, n$$

我们称 $C = (c_{ij})_{i,j}$ 为随机变量 $(X_1, X_2, \dots, X_n)$ 的*协方差矩阵*.

注释　协方差矩阵是一个对称的非负定矩阵.

n 维正态分布

二维随机变量 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 的概率密度函数 $f(x_1, x_2)$ 为

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} exp\left\{\frac{-1}{2(1-\rho^2)}\left(\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right)\right\}$$

其中 $\sigma_1, \sigma_2 > 0, -1 < \rho < 1$.

n 维正态分布

二维随机变量 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 的概率密度函数 $f(x_1, x_2)$ 为

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} exp\left\{\frac{-1}{2(1-\rho^2)}\left(\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right)\right\}$$

其中 $\sigma_1, \sigma_2 > 0, -1 < \rho < 1$.

我们可以利用协方差矩阵将其整理为:

$$f(x_1, x_2) = \frac{1}{(2\pi)^{2/2}(\det C)^{1/2}} exp\left\{-\frac{1}{2}(x-\mu)^\top C^{-1}(x-\mu)\right\}$$

此处

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \qquad \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \qquad C = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$$

n 维正态分布

二维随机变量 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 的概率密度函数 $f(x_1, x_2)$ 为

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{\frac{-1}{2(1-\rho^2)}\left(\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right)\right\}$$

其中 $\sigma_1, \sigma_2 > 0, -1 < \rho < 1$.

我们可以利用协方差矩阵将其整理为:

$$f(x_1, x_2) = \frac{1}{(2\pi)^{2/2}(\det C)^{1/2}} \exp\left\{-\frac{1}{2}(x-\mu)^\top C^{-1}(x-\mu)\right\}$$

此处

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \qquad \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \qquad C = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$$

由此, 二维到 n 维的扩展就是将向量和矩阵的维度从 2 扩展到 n: n 维正态随机变量 $(X_1, X_2, \ldots, X_n)$ 的概率密度函数为

$$f(x_1, x_2, \ldots, x_n) = \frac{1}{(2\pi)^{n/2}(\det C)^{1/2}} \exp\left\{-\frac{1}{2}(x-\mu)^\top C^{-1}(x-\mu)\right\}$$

其中$\mu = (\mu_1, \mu_2, \ldots, \mu_n)^\top$, C 是$(X_1, X_2, \ldots, X_n)$的协方差矩阵.

n 维正态分布的性质

我们用 $(X_1, X_2, \dots, X_n) \sim N(n)$ 表示 $(X_1, X_2, \dots, X_n)$ 符合 n 维正态分布 (即, 我们只作定性描述, 忽略正态分布的参数). n 维正态分布具有如下性质:

1. 可组合性: 对任意的 $i = 1, 2, \dots, n$, 有

$$(X_1, X_2, \dots, X_n) \sim N(n) \quad \Longrightarrow \quad X_i \sim N(1);$$

n 维正态分布的性质

我们用 $(X_1, X_2, \dots, X_n) \sim N(n)$ 表示 $(X_1, X_2, \dots, X_n)$ 符合 n 维正态分布 (即, 我们只作定性描述, 忽略正态分布的参数). n 维正态分布具有如下性质:

1. 可组合性: 对任意的 $i = 1, 2, \dots, n$, 有

$$(X_1, X_2, \dots, X_n) \sim N(n) \quad \Longrightarrow \quad X_i \sim N(1);$$

当 $X_1, X_2, \dots, X_n$ 相互独立时, 有

$$X_i \sim N(1), \forall i = 1, 2, \dots, n \quad \Longrightarrow \quad (X_1, X_2, \dots, X_n) \sim N(n)$$

n 维正态分布的性质

我们用 $(X_1, X_2, \dots, X_n) \sim N(n)$ 表示 $(X_1, X_2, \dots, X_n)$ 符合 n 维正态分布 (即, 我们只作定性描述, 忽略正态分布的参数). n 维正态分布具有如下性质:

1. 可组合性: 对任意的 $i = 1, 2, \dots, n$, 有

$$(X_1, X_2, \dots, X_n) \sim N(n) \quad \Longrightarrow \quad X_i \sim N(1);$$

   当 $X_1, X_2, \dots, X_n$ 相互独立时, 有

$$X_i \sim N(1), \forall i = 1, 2, \dots, n \quad \Longrightarrow \quad (X_1, X_2, \dots, X_n) \sim N(n)$$

2. 线性性: 对不全为零的 $\ell_1, \ell_2, \dots, \ell_n$, 有

$$(X_1, X_2, \dots, X_n) \sim N(n) \quad \Longleftrightarrow \quad \ell_1 X_1 + \ell_2 X_2 + \cdots + \ell_n X_n \sim N(1);$$

n 维正态分布的性质

我们用 $(X_1, X_2, \dots, X_n) \sim N(n)$ 表示 $(X_1, X_2, \dots, X_n)$ 符合 n 维正态分布 (即, 我们只作定性描述, 忽略正态分布的参数). n 维正态分布具有如下性质:

1. 可组合性: 对任意的 $i = 1, 2, \dots, n$, 有

$$(X_1, X_2, \dots, X_n) \sim N(n) \quad \Longrightarrow \quad X_i \sim N(1);$$

   当 $X_1, X_2, \dots, X_n$ 相互独立时, 有

$$X_i \sim N(1), \forall i = 1, 2, \dots, n \quad \Longrightarrow \quad (X_1, X_2, \dots, X_n) \sim N(n)$$

2. 线性性: 对不全为零的 $\ell_1, \ell_2, \dots, \ell_n$, 有

$$(X_1, X_2, \dots, X_n) \sim N(n) \quad \Longleftrightarrow \quad \ell_1 X_1 + \ell_2 X_2 + \cdots + \ell_n X_n \sim N(1);$$

3. 线性变换不变性: 对任意的 $L \in \mathbb{R}^{n \times m}$, 有

$$(X_1, X_2, \dots, X_n) \sim N(n) \quad \Longrightarrow \quad (X_1, X_2, \cdots, X_n) L \sim N(m);$$

n 维正态分布的性质

我们用 $(X_1, X_2, \dots, X_n) \sim N(n)$ 表示 $(X_1, X_2, \dots, X_n)$ 符合 n 维正态分布 (即, 我们只作定性描述, 忽略正态分布的参数). n 维正态分布具有如下性质:

1. 可组合性: 对任意的 $i = 1, 2, \dots, n$, 有

$$(X_1, X_2, \dots, X_n) \sim N(n) \quad \Longrightarrow \quad X_i \sim N(1);$$

   当 $X_1, X_2, \dots, X_n$ 相互独立时, 有

$$X_i \sim N(1), \forall i = 1, 2, \dots, n \quad \Longrightarrow \quad (X_1, X_2, \dots, X_n) \sim N(n)$$

2. 线性性: 对不全为零的 $\ell_1, \ell_2, \dots, \ell_n$, 有

$$(X_1, X_2, \dots, X_n) \sim N(n) \quad \Longleftrightarrow \quad \ell_1 X_1 + \ell_2 X_2 + \cdots + \ell_n X_n \sim N(1);$$

3. 线性变换不变性: 对任意的 $L \in \mathbb{R}^{n \times m}$, 有

$$(X_1, X_2, \dots, X_n) \sim N(n) \quad \Longrightarrow \quad (X_1, X_2, \cdots, X_n)L \sim N(m);$$

4. 若 $(X_1, X_2, \dots, X_n) \sim N(n)$, 则它们相互独立等价于两两不相关.

大 数 定 律

引入

回顾 频率的稳定性。随机事件 A 的频率 $f_n(A)$ 当重复试验的次数 n 增大时总呈现出稳定性. 频率的稳定性是概率定义的客观基础.

引入

回顾 频率的稳定性。随机事件 A 的频率 $f_n(A)$ 当重复试验的次数 n 增大时总呈现出稳定性. 频率的稳定性是概率定义的客观基础.

例题 6

测量一个工件时, 由于测量具有误差, 以各次测量的平均值来作为测量的结果, 而且只要测量的次数足够多, 总可以达到要求的精度.

引入

回顾 频率的稳定性。随机事件 A 的频率 $f_n(A)$ 当重复试验的次数 n 增大时总呈现出稳定性. 频率的稳定性是概率定义的客观基础.

例题 6

测量一个工件时, 由于测量具有误差, 以各次测量的平均值来作为测量的结果, 而且只要测量的次数足够多, 总可以达到要求的精度.

这些都体现为概率论的基础理论——大数定律. 粗略地说, 大数定律是指: 随机变量序列的前一些项的算数平均值在一定条件下收敛到这些项的均值.

引入

回顾 频率的稳定性。随机事件 A 的频率 $f_n(A)$ 当重复试验的次数 n 增大时总呈现出稳定性. 频率的稳定性是概率定义的客观基础.

例题 6

测量一个工件时, 由于测量具有误差, 以各次测量的平均值来作为测量的结果, 而且只要测量的次数足够多, 总可以达到要求的精度.

这些都体现为概率论的基础理论——大数定律. 粗略地说, 大数定律是指: 随机变量序列的前一些项的算数平均值在一定条件下收敛到这些项的均值.

大数定律不是单个的定理, 而是有各种不同版本, 我们这里介绍几种.

引入

问题

设有一大批产品, 其不合格品率为 p. 现一个接一个地检查产品的合格性, 记前 n 次检查发现 S_n 个不合格品, 而 $\nu_n = S_n/n$ 为不合格品出现的频率.

引入

问题

设有一大批产品, 其不合格品率为 p. 现一个接一个地检查产品的合格性, 记前 n 次检查发现 S_n 个不合格品, 而 $\nu_n = S_n/n$ 为不合格品出现的频率.

检查给出频率序列 $\{\nu_n\}$, 我们有如下两个现象:

- 频率 ν_n 对概率 p 的绝对偏差 $|\nu_n - p|$ 将随 n 增大而呈现逐渐减小的趋势, 但无法说它收敛于零.

引入

问题

设有一大批产品, 其不合格品率为 p. 现一个接一个地检查产品的合格性, 记前 n 次检查发现 S_n 个不合格品, 而 $\nu_n = S_n/n$ 为不合格品出现的频率.

检查给出频率序列 $\{\nu_n\}$, 我们有如下两个现象:

- 频率 ν_n 对概率 p 的绝对偏差 $|\nu_n - p|$ 将随 n 增大而呈现逐渐减小的趋势, 但无法说它收敛于零.
- 由于频率的随机性, 绝对偏差 $|\nu_n - p|$ 时大时小. 虽然我们无法排除大偏差发生的可能性, 但随着 n 不断增大, 大偏差发生的可能性会越来越小.

引入

问题

设有一大批产品, 其不合格品率为 p. 现一个接一个地检查产品的合格性, 记前 n 次检查发现 S_n 个不合格品, 而 $\nu_n = S_n/n$ 为不合格品出现的频率.

检查给出频率序列 $\{\nu_n\}$, 我们有如下两个现象:

- 频率 ν_n 对概率 p 的绝对偏差 $|\nu_n - p|$ 将随 n 增大而呈现逐渐减小的趋势, 但无法说它收敛于零.
- 由于频率的随机性, 绝对偏差 $|\nu_n - p|$ 时大时小. 虽然我们无法排除大偏差发生的可能性, 但随着 n 不断增大, 大偏差发生的可能性会越来越小.

这是一种新的极限概念: 对任意给定的 $\varepsilon > 0$, 随着 n 增大, 事件 $\{|\nu_n - p| \geqslant \varepsilon\}$ 出现 (发生大偏差) 的可能性越来越小, 即

$$n \to \infty, \quad P\{|\nu_n - p| \geqslant \varepsilon\} \to 0.$$

引入

问题

设有一大批产品, 其不合格品率为 p. 现一个接一个地检查产品的合格性, 记前 n 次检查发现 S_n 个不合格品, 而 $\nu_n = S_n/n$ 为不合格品出现的频率.

检查给出频率序列 $\{\nu_n\}$, 我们有如下两个现象:

- 频率 ν_n 对概率 p 的绝对偏差 $|\nu_n - p|$ 将随 n 增大而呈现逐渐减小的趋势, 但无法说它收敛于零.
- 由于频率的随机性, 绝对偏差 $|\nu_n - p|$ 时大时小. 虽然我们无法排除大偏差发生的可能性, 但随着 n 不断增大, 大偏差发生的可能性会越来越小.

这是一种新的极限概念: 对任意给定的 $\varepsilon > 0$, 随着 n 增大, 事件 $\{|\nu_n - p| \geqslant \varepsilon\}$ 出现 (发生大偏差) 的可能性越来越小, 即

$$n \to \infty, \quad P\{|\nu_n - p| \geqslant \varepsilon\} \to 0.$$

这时就可称频率序列 $\{\nu_n\}$ *依概率收敛*. 这就是 “频率稳定于概率” 的含义.

预备

定义 13 (概率收敛)

设 $Y_1, \ldots, Y_n, \ldots$ 是随机变量序列, A 是一个常数. 若对任意 $\epsilon > 0$, 有

$$\lim_{n\to\infty} P\{|Y_n - A| < \epsilon\} = 1 \quad \text{或者} \quad \lim_{n\to\infty} P\{|Y_n - A| \geqslant \epsilon\} = 0$$

则称 $Y_1, \ldots, Y_n, \ldots$ 依概率收敛于 A, 记作

$$Y_n \xrightarrow{P} A.$$

预备

定义 13 (概率收敛)

设 $Y_1, \dots, Y_n, \dots$ 是随机变量序列, A 是一个常数. 若对任意 $\epsilon > 0$, 有

$$\lim_{n\to\infty} P\{|Y_n - A| < \epsilon\} = 1 \quad \text{或者} \quad \lim_{n\to\infty} P\{|Y_n - A| \geqslant \epsilon\} = 0$$

则称 $Y_1, \dots, Y_n, \dots$ 依概率收敛于 A, 记作

$$Y_n \xrightarrow{P} A.$$

定理 14

若函数 $g(x, y)$ 在点 (a, b) 处连续, 则

$$X_n \xrightarrow{P} a, Y_n \xrightarrow{P} b \quad \Longrightarrow \quad g(X_n, Y_n) \xrightarrow{P} g(a, b).$$

预备

定义 13 (概率收敛)

设 $Y_1, \dots, Y_n, \dots$ 是随机变量序列, A 是一个常数. 若对任意 $\epsilon > 0$, 有

$$\lim_{n\to\infty} P\{|Y_n - A| < \epsilon\} = 1 \quad \text{或者} \quad \lim_{n\to\infty} P\{|Y_n - A| \geqslant \epsilon\} = 0$$

则称 $Y_1, \dots, Y_n, \dots$ 依概率收敛于 A, 记作

$$Y_n \xrightarrow{P} A.$$

定理 14

若函数 $g(x, y)$ 在点 (a, b) 处连续, 则

$$X_n \xrightarrow{P} a, Y_n \xrightarrow{P} b \quad \Longrightarrow \quad g(X_n, Y_n) \xrightarrow{P} g(a, b).$$

定义 15

设随机变量 $X_1, X_2, \dots, X_n$, 定义 $\overline{X}_n = \dfrac{X_1 + X_2 + \cdots + X_n}{n}$.

大数定律

一般的大数定律都涉及一个随机变量序列 $\{X_n\}$, 其一般形式如下.

定义 16

设有一随机变量序列 $\{X_n\}$, 假如它满足**[某些条件]**, 则

$$\lim_{n\to\infty} P\left\{\left|\frac{1}{n}\sum_{i=1}^{n} X_i - \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}(X_i)\right| < \varepsilon\right\} = 1 \quad \text{或} \quad \frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{P} \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}(X_i)$$

我们称该随机变量序列 $\{X_n\}$ 服从大数定律.

大数定律

一般的大数定律都涉及一个随机变量序列 $\{X_n\}$, 其一般形式如下.

定义 16

设有一随机变量序列 $\{X_n\}$, 假如它满足**[某些条件]**, 则

$$\lim_{n\to\infty} P\left\{\left|\frac{1}{n}\sum_{i=1}^{n} X_i - \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}(X_i)\right| < \varepsilon\right\} = 1 \quad \text{或} \quad \frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{P} \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}(X_i)$$

我们称该随机变量序列 $\{X_n\}$ 服从大数定律.

核心问题是: 随机变量序列 $\{X_n\}$ 在什么条件下服从大数定律? 它们之间的差别表现在条件上: 有的是相互独立的随机变量序列, 有的是相依的随机变量序列, 有的是同分布的随机变量序列, 有的是不同分布的随机变量序列等等. 我们考察下面几个重要的大数定律, 且假定随机变量序列中变量具有相同的期望. **注意: 我们给出的大数定律在期望不同的情况下也成立.**

大数定律

定理 17 (马尔可夫大数定律)

设 $X_1, \ldots, X_n, \ldots$ 具有相同的数学期望 μ, 且满足马尔可夫条件: $n \to 0, \frac{1}{n^2}\mathbb{D}\left(\sum_{i=1}^{n} X_i\right) \to 0$, 则

$$\overline{X}_n \xrightarrow{P} \mu$$

大数定律

定理 17 (马尔可夫大数定律)

设 $X_1, \dots, X_n, \dots$ 具有相同的数学期望 μ, 且满足马尔可夫条件: $n \to 0$, $\frac{1}{n^2}\mathbb{D}\left(\sum_{i=1}^{n} X_i\right) \to 0$, 则

$$\overline{X}_n \xrightarrow{P} \mu$$

定理 18 (切比雪夫大数定律)

设 $X_1, \dots, X_n, \dots$ 相互独立, 且具有相同的数学期望 μ 和方差存在且不超过 σ^2, 则

$$\overline{X}_n \xrightarrow{P} \mu$$

大数定律

定理 17 (马尔可夫大数定律)

设 $X_1, \dots, X_n, \dots$ 具有相同的数学期望 μ, 且满足马尔可夫条件: $n \to 0$, $\frac{1}{n^2}\mathbb{D}\left(\sum_{i=1}^{n} X_i\right) \to 0$, 则

$$\overline{X}_n \xrightarrow{P} \mu$$

定理 18 (切比雪夫大数定律)

设 $X_1, \dots, X_n, \dots$ 相互独立, 且具有相同的数学期望 μ 和方差存在且不超过 σ^2, 则

$$\overline{X}_n \xrightarrow{P} \mu$$

定理 19 (辛钦大数定律, 弱大数定理)

设随机变量 $X_1, \dots, X_n, \dots$, 相互独立同分布, 且数学期望为 μ, 则

$$\overline{X}_n \xrightarrow{P} \mu.$$

大数定律

我们容易给出切比雪夫大数定律的证明.

定理 20 (切比雪夫大数定律)

设 $X_1, \ldots, X_n, \ldots$ 相互独立, 且具有相同的数学期望 μ 和方差 σ^2, 则

$$\overline{X}_n \xrightarrow{P} \mu$$

大数定律

我们容易给出切比雪夫大数定律的证明.

定理 20 (切比雪夫大数定律)

设 $X_1, \dots, X_n, \dots$ 相互独立, 且具有相同的数学期望 μ 和方差 σ^2, 则

$$\overline{X}_n \xrightarrow{P} \mu$$

证明. 由变量的独立性、数学期望和方差的性质, 我们知道:

$$\mathbb{E}(\overline{X}_n) = \mu, \quad \mathbb{D}(\overline{X}_n) = \frac{\sigma^2}{n}$$

大数定律

我们容易给出切比雪夫大数定律的证明.

定理 20 (切比雪夫大数定律)

设 $X_1, \dots, X_n, \dots$ 相互独立, 且具有相同的数学期望 μ 和方差 σ^2, 则

$$\overline{X}_n \xrightarrow{P} \mu$$

证明. 由变量的独立性、数学期望和方差的性质, 我们知道:

$$\mathbb{E}(\overline{X}_n) = \mu, \quad \mathbb{D}(\overline{X}_n) = \frac{\sigma^2}{n}$$

利用切比雪夫不等式, 我们有

$$P\{|\overline{X}_n - \mu| \geqslant \epsilon\} \leqslant \frac{\sigma^2}{n\epsilon^2}$$

大数定律

我们容易给出切比雪夫大数定律的证明.

定理 20 (切比雪夫大数定律)

设 $X_1, \dots, X_n, \dots$ 相互独立, 且具有相同的数学期望 μ 和方差 σ^2, 则

$$\overline{X}_n \xrightarrow{P} \mu$$

证明. 由变量的独立性、数学期望和方差的性质, 我们知道:

$$\mathbb{E}(\overline{X}_n) = \mu, \quad \mathbb{D}(\overline{X}_n) = \frac{\sigma^2}{n}$$

利用切比雪夫不等式, 我们有

$$P\{|\overline{X}_n - \mu| \geqslant \epsilon\} \leqslant \frac{\sigma^2}{n\epsilon^2}$$

因为概率的非负性, 利用夹逼定理可以得到 $\lim_{n\to\infty} P\{|\overline{X}_n - \mu| \geqslant \epsilon\} = 0$. 得证.

伯努利试验的大数定律

现在将大数定律应用于伯努利实验, 这就证明了频率和概率的关系.

定理 21 (伯努利大数定律)

设 $f_n(A)$ 为 n 重伯努利试验中事件 A 的频率, p 是该事件的概率, 则

$$f_n(A) \xrightarrow{P} p.$$

伯努利试验的大数定律

现在将大数定律应用于伯努利实验, 这就证明了频率和概率的关系.

定理 21 (伯努利大数定律)

设 $f_n(A)$ 为 n 重伯努利试验中事件 A 的频率, p 是该事件的概率, 则

$$f_n(A) \xrightarrow{P} p.$$

根据“依概率收敛”的定义, 伯努利大数定律说明: **对任意小的正数 ϵ, 在 n 充分大的时候, 事件“频率 $f_n(A)$ 与概率 p 的偏差超过 ϵ”是小概率事件**.

伯努利试验的大数定律

现在将大数定律应用于伯努利实验, 这就证明了频率和概率的关系.

定理 21 (伯努利大数定律)

设 $f_n(A)$ 为 n 重伯努利试验中事件 A 的频率, p 是该事件的概率, 则

$$f_n(A) \xrightarrow{P} p.$$

根据“依概率收敛”的定义, 伯努利大数定律说明: **对任意小的正数 ϵ, 在 n 充分大的时候, 事件“频率 $f_n(A)$ 与概率 p 的偏差超过 ϵ”是小概率事件**.

这是频率稳定性的严格数学描述. 根据实际推断原理, 当实验次数很大时, 便可用事件的频率来代替事件的概率.

伯努利试验的大数定律

定理 22 (伯努利大数定律)

设 $f_n(A)$ 为 n 重伯努利试验中事件 A 的频率, p 是该事件的概率, 则

$$f_n(A) \xrightarrow{P} p.$$

伯努利试验的大数定律

定理 22 (伯努利大数定律)

设 $f_n(A)$ 为 n 重伯努利试验中事件 A 的频率, p 是该事件的概率, 则

$$f_n(A) \xrightarrow{P} p.$$

证明. 首先, 我们明确 $f_n(A)$ 是一个随机变量; 且根据伯努利分布的定义:

$$f_n(A) = \frac{X_1 + \cdots + X_n}{n}, \quad X_k \sim B(1,p), \quad \forall k = 1, \ldots, n$$

此处 $X_1, \ldots, X_n$ 相互独立.

伯努利试验的大数定律

定理 22 (伯努利大数定律)

设 $f_n(A)$ 为 n 重伯努利试验中事件 A 的频率, p 是该事件的概率, 则

$$f_n(A) \xrightarrow{P} p.$$

证明. 首先, 我们明确 $f_n(A)$ 是一个随机变量; 且根据伯努利分布的定义:

$$f_n(A) = \frac{X_1 + \cdots + X_n}{n}, \quad X_k \sim B(1,p), \quad \forall k = 1, \ldots, n$$

此处 $X_1, \ldots, X_n$ 相互独立. 由伯努利分布的知识可知

$$\mathbb{E}(X_k) = p, \qquad \mathbb{D}(X_k) = p(1-p), \quad \forall k = 1, \ldots, n$$

伯努利试验的大数定律

定理 22 (伯努利大数定律)

设 $f_n(A)$ 为 n 重伯努利试验中事件 A 的频率, p 是该事件的概率, 则

$$f_n(A) \xrightarrow{P} p.$$

证明. 首先, 我们明确 $f_n(A)$ 是一个随机变量; 且根据伯努利分布的定义:

$$f_n(A) = \frac{X_1 + \cdots + X_n}{n}, \quad X_k \sim B(1,p), \quad \forall k = 1, \ldots, n$$

此处 $X_1, \ldots, X_n$ 相互独立. 由伯努利分布的知识可知

$$\mathbb{E}(X_k) = p, \qquad \mathbb{D}(X_k) = p(1-p), \quad \forall k = 1, \ldots, n$$

根据切比雪夫大数定律可知:

$$f_n(A) = \overline{X}_n \xrightarrow{P} \mathbb{E}(X_k) = p.$$

中心极限定理

中心极限定理：预备

在实际中, 有些随机变量由大量相互独立的随机因素综合影响, 而其中个别因素对总体的影响微小. 这种随机变量往往近似服从正态分布, 这种现象就是中心极限定理的客观背景.

中心极限定理：预备

在实际中, 有些随机变量由大量相互独立的随机因素综合影响, 而其中个别因素对总体的影响微小. 这种随机变量往往近似服从正态分布, 这种现象就是中心极限定理的客观背景. 我们考虑一个简单的情形: 随机变量可以表示成很多个独立的随机变量之和. 例如,

- 在任一指定时刻, 一个城市的耗电量是大量用户耗电量的总和;
- 物理实验的测量误差由许多观察不到的、可加的微小误差合成;

它们往往近似服从正态分布.

中心极限定理：预备

在实际中, 有些随机变量由大量相互独立的随机因素综合影响, 而其中个别因素对总体的影响微小. 这种随机变量往往近似服从正态分布, 这种现象就是中心极限定理的客观背景. 我们考虑一个简单的情形: 随机变量可以表示成很多个独立的随机变量之和. 例如,

- 在任一指定时刻, 一个城市的耗电量是大量用户耗电量的总和;
- 物理实验的测量误差由许多观察不到的、可加的微小误差合成;

它们往往近似服从正态分布. 中心极限定理说明了正态分布的重要地位, 它也是统计学中处理大样本时的重要工具.

中心极限定理：预备

定义 23

设随机变量 $X_1, X_2, \ldots, X_n$, 定义 $\widetilde{X}_n = X_1 + X_2 + \cdots + X_n = n\overline{X}_n$.

中心极限定理：预备

定义 23

设随机变量 $X_1, X_2, \ldots, X_n$, 定义 $\widetilde{X}_n = X_1 + X_2 + \cdots + X_n = n\overline{X}_n$.

定义 24

设随机变量 $X_1, \ldots, X_n, \ldots$, 它们的分布函数为 $F_1, \ldots, F_n, \ldots$. 又设分布 $\mathcal{D}$ 具有分布函数 F. 若对任意的 $x \in \mathbb{R}$, 有

$$\lim_{n\to\infty} F_n(x) = F(x)$$

我们称当 n 趋向于无穷大时, X_n 服从 $\mathcal{D}$, 记作

$$n \to \infty, \quad X_n \sim \mathcal{D}.$$

中心极限定理：预备

定义 23

设随机变量 $X_1, X_2, \ldots, X_n$, 定义 $\widetilde{X}_n = X_1 + X_2 + \cdots + X_n = n\overline{X}_n$.

定义 24

设随机变量 $X_1, \ldots, X_n, \ldots$, 它们的分布函数为 $F_1, \ldots, F_n, \ldots$. 又设分布 $\mathcal{D}$ 具有分布函数 F. 若对任意的 $x \in \mathbb{R}$, 有

$$\lim_{n\to\infty} F_n(x) = F(x)$$

我们称当 n 趋向于无穷大时, X_n 服从 $\mathcal{D}$, 记作

$$n \to \infty, \quad X_n \sim \mathcal{D}.$$

分布 $\mathcal{D}$ 也可以取决于 n, 即分布的参数取决于 n.

独立同分布的情形

我们考虑简单的情形: $X_1, X_2, \ldots$ 独立同分布且数学期望和方差均存在.

定理 25 (独立同分布的中心极限定理)

设随机变量 $X_1, X_2, \ldots, X_n, \ldots$ 独立同分布, 其期望和方差均为 μ 和 $\sigma^2 > 0$, 则

$$n \to \infty, \quad \widetilde{X}_n \sim N(n\mu, n\sigma^2)$$

独立同分布的情形

我们考虑简单的情形: $X_1, X_2, \ldots$ 独立同分布且数学期望和方差均存在.

定理 25 (独立同分布的中心极限定理)

设随机变量 $X_1, X_2, \ldots, X_n, \ldots$ 独立同分布, 其期望和方差均为 μ 和 $\sigma^2 > 0$, 则

$$n \to \infty, \quad \widetilde{X}_n \sim N(n\mu, n\sigma^2)$$

注释 定理的结论部分有其他形式: 针对 $\widetilde{X}_n$ 的标准化变量, 有

$$n \to \infty, \quad \frac{\widetilde{X}_n - n\mu}{\sqrt{n}\sigma} \sim N(0,1)$$

独立同分布的情形

我们考虑简单的情形: $X_1, X_2, \ldots$ 独立同分布且数学期望和方差均存在.

定理 25 (独立同分布的中心极限定理)

设随机变量 $X_1, X_2, \ldots, X_n, \ldots$ 独立同分布, 其期望和方差均为 μ 和 $\sigma^2 > 0$, 则

$$n \to \infty, \quad \widetilde{X}_n \sim N(n\mu, n\sigma^2)$$

注释 定理的结论部分有其他形式: 针对 $\widetilde{X}_n$ 的标准化变量, 有

$$n \to \infty, \quad \frac{\widetilde{X}_n - n\mu}{\sqrt{n}\sigma} \sim N(0,1)$$

针对算数平均数 $\overline{X}_n$, 有

$$n \to \infty, \quad \overline{X}_n \sim N(\mu, \sigma^2/n) \quad \text{或} \quad \frac{\overline{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$$

独立同分布的情形

例题 7

一生产线生产的产品成箱包装, 每箱的重量是随机的. 假设每箱平均重 50 千克, 标准差为 5 千克. 若用最大载重量为 5 吨的汽车承运, 试利用中心极限定理说明每辆车最多可以装多少箱, 才能保障不超载的概率大于 0.977.

独立同分布的情形

例题 7

一生产线生产的产品成箱包装, 每箱的重量是随机的. 假设每箱平均重 50 千克, 标准差为 5 千克. 若用最大载重量为 5 吨的汽车承运, 试利用中心极限定理说明每辆车最多可以装多少箱, 才能保障不超载的概率大于 0.977.

证明. 设 X_k 是第 k 个箱子的重量, 单位千克, $k = 1, 2, \ldots$. 根据题意, 我们有 $\mathbb{E}(X_k) = 50$, $\mathbb{D}(X_k) = 25$. 我们希望求 n 使得 $P\{\widetilde{X}_n \leqslant 5000\} > 0.977$.

独立同分布的情形

例题 7

一生产线生产的产品成箱包装, 每箱的重量是随机的. 假设每箱平均重 50 千克, 标准差为 5 千克. 若用最大载重量为 5 吨的汽车承运, 试利用中心极限定理说明每辆车最多可以装多少箱, 才能保障不超载的概率大于 0.977.

证明. 设 X_k 是第 k 个箱子的重量, 单位千克, $k = 1, 2, \ldots$. 根据题意, 我们有 $\mathbb{E}(X_k) = 50$, $\mathbb{D}(X_k) = 25$. 我们希望求 n 使得 $P\{\tilde{X}_n \leqslant 5000\} > 0.977$. 根据定理, 我们可以近似地认为 $\tilde{X}_n \sim N(50n, 25n)$, 所以有

$$P\{\tilde{X}_n \leqslant 5000\} = P\left\{\frac{\tilde{X}_n - 50n}{5\sqrt{n}} \leqslant \frac{5000 - 50n}{5\sqrt{n}}\right\} = \Phi\left(\frac{5000 - 50n}{5\sqrt{n}}\right) > 0.977$$

独立同分布的情形

例题 7

一生产线生产的产品成箱包装, 每箱的重量是随机的. 假设每箱平均重 50 千克, 标准差为 5 千克. 若用最大载重量为 5 吨的汽车承运, 试利用中心极限定理说明每辆车最多可以装多少箱, 才能保障不超载的概率大于 0.977.

证明. 设 X_k 是第 k 个箱子的重量, 单位千克, $k = 1, 2, \ldots$. 根据题意, 我们有 $\mathbb{E}(X_k) = 50$, $\mathbb{D}(X_k) = 25$. 我们希望求 n 使得 $P\{\widetilde{X}_n \leqslant 5000\} > 0.977$. 根据定理, 我们可以近似地认为 $\widetilde{X}_n \sim N(50n, 25n)$, 所以有

$$P\{\widetilde{X}_n \leqslant 5000\} = P\left\{\frac{\tilde{X}_n - 50n}{5\sqrt{n}} \leqslant \frac{5000 - 50n}{5\sqrt{n}}\right\} = \Phi\left(\frac{5000 - 50n}{5\sqrt{n}}\right) > 0.977$$

为此, 需要

$$\frac{5000 - 50n}{5\sqrt{n}} > 2 \Longrightarrow n > 102.02 \text{ 或者 } n < 98.02$$

独立同分布的情形

例题 7

一生产线生产的产品成箱包装, 每箱的重量是随机的. 假设每箱平均重 50 千克, 标准差为 5 千克. 若用最大载重量为 5 吨的汽车承运, 试利用中心极限定理说明每辆车最多可以装多少箱, 才能保障不超载的概率大于 0.977.

证明. 设 X_k 是第 k 个箱子的重量, 单位千克, $k=1,2,\cdots$. 根据题意, 我们有 $\mathbb{E}(X_k)=50$, $\mathbb{D}(X_k)=25$. 我们希望求 n 使得 $P\{\widetilde{X}_n \leqslant 5000\} > 0.977$. 根据定理, 我们可以近似地认为 $\widetilde{X}_n \sim N(50n, 25n)$, 所以有

$$P\{\widetilde{X}_n \leqslant 5000\} = P\left\{\frac{\tilde{X}_n - 50n}{5\sqrt{n}} \leqslant \frac{5000-50n}{5\sqrt{n}}\right\} = \Phi\left(\frac{5000-50n}{5\sqrt{n}}\right) > 0.977$$

为此, 需要

$$\frac{5000-50n}{5\sqrt{n}} > 2 \Longrightarrow n > 102.02 \text{ 或者 } n < 98.02$$

由于汽车的最大载重量为 5 吨, 故取 $n=98$.

一般情形

现在考虑更加一般的情形: $X_1, X_2, \ldots$ 独立不同分布, 但是数学期望和方差依然均存在.

定理 26 (李雅普诺夫定理)

设随机变量 $X_1, X_2, \ldots, X_n, \ldots$ 相互独立, 其数学期望和方差均为

$$\mathbb{E}(X_k) = \mu_k, \quad \mathbb{D}(X_k) = \sigma_k^2 > 0, \quad \forall k = 1, 2, \ldots$$

令 $B_n^2 = \sum_{k=1}^{n} \sigma_k^2$. 若存在正数 δ 使得

$$n \to \infty, \quad \frac{1}{B_n^{2+\delta}} \sum_{k=1}^{n} \mathbb{E}(|X_k - \mu_k|^{2+\delta}) \to 0$$

则

$$n \to \infty, \quad \widetilde{X}_n \sim N\left(\sum_{k=1}^{n} \mu_k, B_n^2\right) \quad \text{或者} \quad \frac{\widetilde{X}_n - \sum_{k=1}^{n} \mu_k}{B_n} \sim N(0, 1)$$

二项分布的中心极限

利用中心极限定理, 我们可以获得二项分布的另外一个近似分布.

定理 27 (德莫佛-拉普拉斯定理)

设 $\eta_n \sim B(n,p)$, 则

$$n \to \infty, \quad \eta_n \sim N(np, np(1-p)) \quad \text{或者} \quad \frac{\eta_n - np}{\sqrt{np(1-p)}} \sim N(0,1).$$

二项分布的中心极限

利用中心极限定理, 我们可以获得二项分布的另外一个近似分布.

定理 27 (德莫佛-拉普拉斯定理)

设 $\eta_n \sim B(n,p)$, 则

$$n \to \infty, \quad \eta_n \sim N(np, np(1-p)) \quad \text{或者} \quad \frac{\eta_n - np}{\sqrt{np(1-p)}} \sim N(0,1).$$

注释 当 n 充分大时, 可以利用正态分布来计算二项分布的概率.

二项分布的中心极限

利用中心极限定理, 我们可以获得二项分布的另外一个近似分布.

定理 27 (德莫佛-拉普拉斯定理)

设 $\eta_n \sim B(n,p)$, 则

$$n \to \infty, \quad \eta_n \sim N(np, np(1-p)) \quad \text{或者} \quad \frac{\eta_n - np}{\sqrt{np(1-p)}} \sim N(0,1).$$

注释 当 n 充分大时, 可以利用正态分布来计算二项分布的概率.

注释 当 n 很大但 p 很小, 我们可以利用泊松定理将其近似为参数为 np 的泊松分布. 定理说明, 即使不考虑条件, 其近似服从正态分布.

二项分布的中心极限

利用中心极限定理, 我们可以获得二项分布的另外一个近似分布.

定理 28 (德莫佛-拉普拉斯定理)

设 $\eta_n \sim B(n,p)$, 则

$$n \to \infty, \quad \eta_n \sim N(np, np(1-p)) \quad \text{或者} \quad \frac{\eta_n - np}{\sqrt{np(1-p)}} \sim N(0,1).$$

二项分布的中心极限

利用中心极限定理, 我们可以获得二项分布的另外一个近似分布.

定理 28 (德莫佛-拉普拉斯定理)

设 $\eta_n \sim B(n,p)$, 则

$$n \to \infty, \quad \eta_n \sim N(np, np(1-p)) \quad \text{或者} \quad \frac{\eta_n - np}{\sqrt{np(1-p)}} \sim N(0,1).$$

证明. 根据二项分布的定义可知:

$$\eta_n = X_1 + X_2 + \cdots + X_n, \qquad X_k \sim B(1,p),$$

其中 $X_1, \ldots, X_n$ 相互独立.

二项分布的中心极限

利用中心极限定理, 我们可以获得二项分布的另外一个近似分布.

定理 28 (德莫佛-拉普拉斯定理)

设 $\eta_n \sim B(n,p)$, 则

$$n \to \infty, \quad \eta_n \sim N(np, np(1-p)) \quad \text{或者} \quad \frac{\eta_n - np}{\sqrt{np(1-p)}} \sim N(0,1).$$

证明. 根据二项分布的定义可知:

$$\eta_n = X_1 + X_2 + \cdots + X_n, \qquad X_k \sim B(1,p),$$

其中 $X_1, \ldots, X_n$ 相互独立. 因为

$$\mathbb{E}(X_k) = p, \quad \mathbb{D}(X_k) = p(1-p), \quad k = 1, 2, \ldots, n$$

二项分布的中心极限

利用中心极限定理, 我们可以获得二项分布的另外一个近似分布.

定理 28 (德莫佛-拉普拉斯定理)

设 $\eta_n \sim B(n,p)$, 则

$$n \to \infty, \quad \eta_n \sim N(np, np(1-p)) \quad \text{或者} \quad \frac{\eta_n - np}{\sqrt{np(1-p)}} \sim N(0,1).$$

证明. 根据二项分布的定义可知:

$$\eta_n = X_1 + X_2 + \cdots + X_n, \qquad X_k \sim B(1,p),$$

其中 $X_1, \ldots, X_n$ 相互独立. 因为

$$\mathbb{E}(X_k) = p, \quad \mathbb{D}(X_k) = p(1-p), \quad k = 1, 2, \ldots, n$$

由独立同分布的中心极限定理即可得证.

德莫佛-拉普拉斯定理的应用案例

例题 8 (第一节课的场景)

车间有 200 台车床独立工作, 开工率为 0.6, 开工时耗电各为 1 千瓦, 问供电所至少要供给这个车间多少电力才能以 99.9% 的概率保证这个车间正常生产?

德莫佛-拉普拉斯定理的应用案例

例题 8 (第一节课的场景)

车间有 200 台车床独立工作, 开工率为 0.6, 开工时耗电各为 1 千瓦, 问供电所至少要供给这个车间多少电力才能以 99.9% 的概率保证这个车间正常生产?

证明. 设某时刻工作着的车床数位 X, 则 $X \sim B(200, 0.6)$. 设为车间供电 r 千瓦, 则根据题意需要求 r 使得 $P\{X \leqslant r\} \geqslant 0.999$.

德莫佛-拉普拉斯定理的应用案例

例题 8 (第一节课的场景)

车间有 200 台车床独立工作, 开工率为 0.6, 开工时耗电各为 1 千瓦, 问供电所至少要供给这个车间多少电力才能以 99.9% 的概率保证这个车间正常生产?

证明. 设某时刻工作着的车床数位 X, 则 $X \sim B(200, 0.6)$. 设为车间供电 r 千瓦, 则根据题意需要求 r 使得 $P\{X \leqslant r\} \geqslant 0.999$. 根据德莫佛-拉普拉斯定理, 我们可以近似地认为 $X \sim N(120, 48)$.

德莫佛-拉普拉斯定理的应用案例

例题 8 (第一节课的场景)

车间有 200 台车床独立工作, 开工率为 0.6, 开工时耗电各为 1 千瓦, 问供电所至少要供给这个车间多少电力才能以 99.9% 的概率保证这个车间正常生产?

证明. 设某时刻工作着的车床数位 X, 则 $X \sim B(200, 0.6)$. 设为车间供电 r 千瓦, 则根据题意需要求 r 使得 $P\{X \leqslant r\} \geqslant 0.999$. 根据德莫佛-拉普拉斯定理, 我们可以近似地认为 $X \sim N(120, 48)$. 因为

$$P\{X \leqslant r\} = P\left\{\frac{X-120}{\sqrt{48}} \leqslant \frac{r-120}{\sqrt{48}}\right\} = \Phi\left(\frac{r-120}{\sqrt{48}}\right) \geqslant 0.999$$

德莫佛-拉普拉斯定理的应用案例

例题 8 (第一节课的场景)

车间有 200 台车床独立工作, 开工率为 0.6, 开工时耗电各为 1 千瓦, 问供电所至少要供给这个车间多少电力才能以 99.9% 的概率保证这个车间正常生产?

证明. 设某时刻工作着的车床数位 X, 则 $X \sim B(200, 0.6)$. 设为车间供电 r 千瓦, 则根据题意需要求 r 使得 $P\{X \leqslant r\} \geqslant 0.999$. 根据德莫佛-拉普拉斯定理, 我们可以近似地认为 $X \sim N(120, 48)$. 因为

$$P\{X \leqslant r\} = P\left\{\frac{X-120}{\sqrt{48}} \leqslant \frac{r-120}{\sqrt{48}}\right\} = \Phi\left(\frac{r-120}{\sqrt{48}}\right) \geqslant 0.999$$

查表可知

$$\frac{r-120}{\sqrt{48}} \geqslant 3.1 \Longrightarrow r \geqslant 141.$$

故供给 141 千瓦电就能保证车间以 99.9% 的概率正常运转.

德莫佛-拉普拉斯定理的应用案例

德莫佛-拉普拉斯定理的一个应用是计算“频率估计概率”的误差: 设 $\eta_n \sim B(n,p)$ 对应 n 重伯努利试验, 则其频率为 $f_n(A)=\eta_n/n$, 我们计算

$$P\left\{\left|\frac{\eta_n}{n}-p\right|<\epsilon\right\} = P\{|\eta_n-np|<n\epsilon\}$$

德莫佛-拉普拉斯定理的应用案例

德莫佛-拉普拉斯定理的一个应用是计算“频率估计概率”的误差: 设 $\eta_n \sim B(n,p)$ 对应 n 重伯努利试验, 则其频率为 $f_n(A)=\eta_n/n$, 我们计算

$$\begin{aligned} P\left\{\left|\frac{\eta_n}{n}-p\right|<\epsilon\right\} &= P\{|\eta_n-np|<n\epsilon\} \\ &= P\left\{-\epsilon\sqrt{\frac{n}{p(1-p)}}<\frac{\eta_n-np}{\sqrt{np(1-p)}}<\epsilon\sqrt{\frac{n}{p(1-p)}}\right\} \end{aligned}$$

德莫佛-拉普拉斯定理的应用案例

德莫佛-拉普拉斯定理的一个应用是计算“频率估计概率”的误差: 设 $\eta_n \sim B(n,p)$ 对应 n 重伯努利试验, 则其频率为 $f_n(A)=\eta_n/n$, 我们计算

$$\begin{aligned} P\left\{\left|\frac{\eta_n}{n}-p\right|<\epsilon\right\} &= P\{|\eta_n-np|<n\epsilon\} \\ &= P\left\{-\epsilon\sqrt{\frac{n}{p(1-p)}}<\frac{\eta_n-np}{\sqrt{np(1-p)}}<\epsilon\sqrt{\frac{n}{p(1-p)}}\right\} \\ &= \Phi\left(\epsilon\sqrt{\frac{n}{p(1-p)}}\right)-\Phi\left(-\epsilon\sqrt{\frac{n}{p(1-p)}}\right) \end{aligned}$$

德莫佛-拉普拉斯定理的应用案例

德莫佛-拉普拉斯定理的一个应用是计算“频率估计概率”的误差: 设 $\eta_n \sim B(n,p)$ 对应 n 重伯努利试验, 则其频率为 $f_n(A)=\eta_n/n$, 我们计算

$$
\begin{aligned}
P\left\{\left|\frac{\eta_n}{n}-p\right|<\epsilon\right\} &= P\{|\eta_n-np|<n\epsilon\} \\
&= P\left\{-\epsilon\sqrt{\frac{n}{p(1-p)}}<\frac{\eta_n-np}{\sqrt{np(1-p)}}<\epsilon\sqrt{\frac{n}{p(1-p)}}\right\} \\
&= \Phi\left(\epsilon\sqrt{\frac{n}{p(1-p)}}\right)-\Phi\left(-\epsilon\sqrt{\frac{n}{p(1-p)}}\right) \\
&= 2\Phi\left(\epsilon\sqrt{\frac{n}{p(1-p)}}\right)-1
\end{aligned}
$$

德莫佛-拉普拉斯定理的应用案例

德莫佛-拉普拉斯定理的一个应用是计算“频率估计概率”的误差: 设 $\eta_n \sim B(n,p)$ 对应 n 重伯努利试验, 则其频率为 $f_n(A)=\eta_n/n$, 我们计算

$$\begin{aligned} P\left\{\left|\frac{\eta_n}{n}-p\right|<\epsilon\right\} &= P\{|\eta_n-np|<n\epsilon\} \\ &= P\left\{-\epsilon\sqrt{\frac{n}{p(1-p)}}<\frac{\eta_n-np}{\sqrt{np(1-p)}}<\epsilon\sqrt{\frac{n}{p(1-p)}}\right\} \\ &= \Phi\left(\epsilon\sqrt{\frac{n}{p(1-p)}}\right)-\Phi\left(-\epsilon\sqrt{\frac{n}{p(1-p)}}\right) \\ &= 2\Phi\left(\epsilon\sqrt{\frac{n}{p(1-p)}}\right)-1 \end{aligned}$$

我们将此误差发生的概率记作 $\beta(p,n,\epsilon)$, 上述结果可以写作:

德莫佛-拉普拉斯定理的应用案例

德莫佛-拉普拉斯定理的一个应用是计算“频率估计概率”的误差: 设 $\eta_n \sim B(n,p)$ 对应 n 重伯努利试验, 则其频率为 $f_n(A)=\eta_n/n$, 我们计算

$$\begin{aligned} P\left\{\left|\frac{\eta_n}{n}-p\right|<\epsilon\right\} &= P\{|\eta_n-np|<n\epsilon\} \\ &= P\left\{-\epsilon\sqrt{\frac{n}{p(1-p)}}<\frac{\eta_n-np}{\sqrt{np(1-p)}}<\epsilon\sqrt{\frac{n}{p(1-p)}}\right\} \\ &= \Phi\left(\epsilon\sqrt{\frac{n}{p(1-p)}}\right)-\Phi\left(-\epsilon\sqrt{\frac{n}{p(1-p)}}\right) \\ &= 2\Phi\left(\epsilon\sqrt{\frac{n}{p(1-p)}}\right)-1 \end{aligned}$$

我们将此误差发生的概率记作 $\beta(p,n,\epsilon)$, 上述结果可以写作:

$$\beta(p,n,\epsilon)=2\cdot\Phi\left(\epsilon\sqrt{\frac{n}{p(1-p)}}\right)-1=2\cdot\Phi\left((p(1-p))^{-1/2}\cdot n^{1/2}\cdot\epsilon\right)-1$$

德莫佛-拉普拉斯定理的应用案例

德莫佛-拉普拉斯定理的一个应用是计算“频率估计概率”的误差: 设 $\eta_n \sim B(n,p)$ 对应 n 重伯努利试验, 则其频率为 $f_n(A)=\eta_n/n$, 我们计算

$$\begin{aligned} P\left\{\left|\frac{\eta_n}{n}-p\right|<\epsilon\right\} &= P\{|\eta_n-np|<n\epsilon\} \\ &= P\left\{-\epsilon\sqrt{\frac{n}{p(1-p)}}<\frac{\eta_n-np}{\sqrt{np(1-p)}}<\epsilon\sqrt{\frac{n}{p(1-p)}}\right\} \\ &= \Phi\left(\epsilon\sqrt{\frac{n}{p(1-p)}}\right)-\Phi\left(-\epsilon\sqrt{\frac{n}{p(1-p)}}\right) \\ &= 2\Phi\left(\epsilon\sqrt{\frac{n}{p(1-p)}}\right)-1 \end{aligned}$$

我们将此误差发生的概率记作 $\beta(p,n,\epsilon)$, 上述结果可以写作:

$$\beta(p,n,\epsilon)=2\cdot\Phi\left(\epsilon\sqrt{\frac{n}{p(1-p)}}\right)-1=2\cdot\Phi\left((p(1-p))^{-1/2}\cdot n^{1/2}\cdot\epsilon\right)-1$$

利用这一关系可以解决许多问题, 例如: 已知 p,n,β, 求 ϵ.

德莫佛-拉普拉斯定理的应用案例

例题 9

某调查公司受委托, 调查某电视节目的收视率 p. 调查公司将所有调查对象中收看此节目的频率作为 p 的估计 $\hat{p}$. 现在要保证有 90% 的把握, 使得调查所得收视率 $\hat{p}$ 与真实收视率 p 之间的差异不大于 5%. 问至少要调查多少对象?

德莫佛-拉普拉斯定理的应用案例

例题 9

某调查公司受委托, 调查某电视节目的收视率 p. 调查公司将所有调查对象中收看此节目的频率作为 p 的估计 $\hat{p}$. 现在要保证有 90% 的把握, 使得调查所得收视率 $\hat{p}$ 与真实收视率 p 之间的差异不大于 5%. 问至少要调查多少对象?

证明. 设共调查 n 个对象, 记

$$X_i = \begin{cases} 1, & \text{第}i\text{个调查对象收看此电视节目} \\ 0, & \text{第}i\text{个调查对象不看此电视节目} \end{cases}$$

德莫佛-拉普拉斯定理的应用案例

例题 9

某调查公司受委托, 调查某电视节目的收视率 p. 调查公司将所有调查对象中收看此节目的频率作为 p 的估计 $\hat{p}$. 现在要保证有 90% 的把握, 使得调查所得收视率 $\hat{p}$ 与真实收视率 p 之间的差异不大于 5%. 问至少要调查多少对象?

证明. 设共调查 n 个对象, 记

$$X_i = \begin{cases} 1, & \text{第}i\text{个调查对象收看此电视节目} \\ 0, & \text{第}i\text{个调查对象不看此电视节目} \end{cases}$$

则 X_i 独立同分布, 且 $P\{X_i = 1\} = p$. 又记 n 个被调查对象中, 收看此电视节目的人数为 Y_n, 则有

$$Y_n = \sum_{i=1}^{n} X_i \sim B(n, p).$$

德莫佛-拉普拉斯定理的应用案例

证明 (续). 已知 $\sum_{i=1}^{n} X_i \sim B(n,p)$. 由德莫佛-拉普拉斯定理有

$$P\left(\left|\frac{1}{n}\sum_{i=1}^{n} X_i - p\right| < 0.05\right) \approx 2\Phi\left(0.05\sqrt{\frac{n}{p(1-p)}}\right) - 1 \geqslant 0.90,$$

德莫佛-拉普拉斯定理的应用案例

证明 (续). 已知 $\sum_{i=1}^{n} X_i \sim B(n,p)$. 由德莫佛-拉普拉斯定理有

$$P\left(\left|\frac{1}{n}\sum_{i=1}^{n} X_i - p\right| < 0.05\right) \approx 2\Phi\left(0.05\sqrt{\frac{n}{p(1-p)}}\right) - 1 \geqslant 0.90,$$

所以

$$\Phi\left(0.05\sqrt{\frac{n}{p(1-p)}}\right) \geqslant 0.95.$$

德莫佛-拉普拉斯定理的应用案例

证明 (续). 已知 $\sum_{i=1}^{n} X_i \sim B(n,p)$. 由德莫佛-拉普拉斯定理有

$$P\left(\left|\frac{1}{n}\sum_{i=1}^{n} X_i - p\right| < 0.05\right) \approx 2\Phi\left(0.05\sqrt{\frac{n}{p(1-p)}}\right) - 1 \geqslant 0.90,$$

所以

$$\Phi\left(0.05\sqrt{\frac{n}{p(1-p)}}\right) \geqslant 0.95.$$

查标准正态分布表可得标准正态分布的 0.95 分位数为 1.645,

德莫佛-拉普拉斯定理的应用案例

证明 (续). 已知 $\sum_{i=1}^{n} X_i \sim B(n,p)$. 由德莫佛-拉普拉斯定理有

$$P\left(\left|\frac{1}{n}\sum_{i=1}^{n} X_i - p\right| < 0.05\right) \approx 2\Phi\left(0.05\sqrt{\frac{n}{p(1-p)}}\right) - 1 \geqslant 0.90,$$

所以

$$\Phi\left(0.05\sqrt{\frac{n}{p(1-p)}}\right) \geqslant 0.95.$$

查标准正态分布表可得标准正态分布的 0.95 分位数为 1.645, 故有

$$0.05\sqrt{\frac{n}{p(1-p)}} \geqslant 1.645,$$

德莫佛-拉普拉斯定理的应用案例

证明 (续). 已知 $\sum_{i=1}^{n} X_i \sim B(n,p)$. 由德莫佛-拉普拉斯定理有

$$P\left(\left|\frac{1}{n}\sum_{i=1}^{n} X_i - p\right| < 0.05\right) \approx 2\Phi\left(0.05\sqrt{\frac{n}{p(1-p)}}\right) - 1 \geqslant 0.90,$$

所以

$$\Phi\left(0.05\sqrt{\frac{n}{p(1-p)}}\right) \geqslant 0.95.$$

查标准正态分布表可得标准正态分布的 0.95 分位数为 1.645, 故有

$$0.05\sqrt{\frac{n}{p(1-p)}} \geqslant 1.645,$$

从中解得

$$n \geqslant p(1-p)\frac{1.645^2}{0.05^2} = p(1-p) \times 1082.41.$$

德莫佛-拉普拉斯定理的应用案例

证明 (续). 已知 $\sum_{i=1}^{n} X_i \sim B(n,p)$. 由德莫佛-拉普拉斯定理有

$$P\left(\left|\frac{1}{n}\sum_{i=1}^{n} X_i - p\right| < 0.05\right) \approx 2\Phi\left(0.05\sqrt{\frac{n}{p(1-p)}}\right) - 1 \geqslant 0.90,$$

所以

$$\Phi\left(0.05\sqrt{\frac{n}{p(1-p)}}\right) \geqslant 0.95.$$

查标准正态分布表可得标准正态分布的 0.95 分位数为 1.645, 故有

$$0.05\sqrt{\frac{n}{p(1-p)}} \geqslant 1.645,$$

从中解得

$$n \geqslant p(1-p)\frac{1.645^2}{0.05^2} = p(1-p) \times 1082.41.$$

又因为 $p(1-p) \leqslant 0.25$, 所以 $n \geqslant 270.6$, 即至少调查 271 个对象.

总结和作业

总结

1. 重要不等式: 马尔可夫不等式 | 切比雪夫不等式
2. 协方差和相关系数: 定义和意义 | 性质 | 二维正态分布的例子
3. 矩: 常见的定义 | 协方差矩阵 | n 维正态分布
4. 大数定律: 依概率收敛 | 马尔可夫、切比雪夫、辛钦大数定律
5. 中心极限定理: 按分布收敛 | 独立同分布的中心极限定理 | 李雅普诺夫定理 | 德莫佛-拉普拉斯定理

总结和作业

总结

1. 重要不等式: 马尔可夫不等式 | 切比雪夫不等式
2. 协方差和相关系数: 定义和意义 | 性质 | 二维正态分布的例子
3. 矩: 常见的定义 | 协方差矩阵 | n 维正态分布
4. 大数定律: 依概率收敛 | 马尔可夫、切比雪夫、辛钦大数定律
5. 中心极限定理: 按分布收敛 | 独立同分布的中心极限定理 | 李雅普诺夫定理 | 德莫佛-拉普拉斯定理

作业

- 第四章习题: 25, 26, 27, 34, 36
- 第五章习题: 3, 5, 12
- 复习第一至第五章——**12 月 7 日期中考试（随堂）**